



VERSIE 1.0.5 · MENSELIJKE ROOSTERS ALS REFERENTIE

Leren van zeven roosters die mensen maakten

Wat de officiële Dordrechtse basisroosters laten zien, hoe dat in de meting en de zoekmachine terecht kwam, wat het opleverde — en drie kandidaatpakketten die nu op een menselijk oordeel wachten.

Standplaats Dordrecht · referentie
DDR_BDU_05_10_2026

20 BEFORE-runs · 2 AFTER-runs
66 kandidaten gemeten
quality-model-v2 · adaptive-
1.0.5

Inhoud

1	Samenvatting	Wat er is gedaan, wat het opleverde en wat nog open is
2	De bron: zeven menselijke roosters	Wat er is ingelezen, gecontroleerd en gemeten
3	Wat de roosters laten zien	Hard tegenover zacht, en twaalf ontwerpprincipes met hun bewijs
4	Metten zoals mensen roosteren	Kwaliteitsmodel v2: wat veranderde tegenover v1, en of het de menselijke roosters herkent
5	Wat er aan de zoekmachine veranderde	Overgangstabel in de solver, bewaking bij het bijschaven, en wat is afgewezen
6	Ontwikkellog	Elke wijziging met reden en gemeten effect, ook wat niet werkte
7	BEFORE en AFTER	Dezelfde meting voor en na, met de eerste AFTER-meting ernaast
8	Per basisrooster	Waar de uitkomst per profiel ligt, en waar de uitschieters zitten
9	Regressies en wat open blijft	Alles wat na de ijking slechter is, of niet is opgelost
10	De drie kandidaatpakketten	Ter beoordeling door de Roostercommissie
11	Hoe de beoordeling werkt	Oordeel per regel en voorkeur tussen kandidaten; wat ermee gebeurt
12	Reproduceerbaarheid en controles	Welke opdracht welk bestand maakt, en wat de tests zeggen

gegenereerd uit `docs/human-roster-benchmark/` en `configs/`. Elk getal komt uit die bestanden. Hoofdstuk 12 noemt per bestand de opdracht die het maakt.

Samenvatting

Wat er is gedaan, wat het opleverde en wat nog open is

De zeven officiële basisroosters van Dordrecht zijn gelezen als menselijke referentie (`HUMAN_ACCEPTED_REFERENCE` , `DDR_BDU_05_10_2026`). Daaruit zijn zachte ontwerpprincipes afgeleid, is het kwaliteitsmodel herijkt (v2) en is de zoekmachine bijgesteld (adaptive-1.0.5). Dezelfde meting van 2 runs voor en na laat zien waar de uitkomst dichterbij de menselijke referentie ligt, en waar niet.

AFTER haalt **5 van de 10** acceptatiepunten uit de werkopdracht (\$75, \$81). Alle 6 AFTER-kandidaten zijn hard geldig, met volledige dekking en zonder profielovertreding. Niet gehaald: minder losse nachten; langere, samenhangender werkblokken; beter herstel na nachten; minder zware slechtste overgang; rust niet noemenswaardig achteruit (marge 1).

De kern: officieel rooster, v1.0.4 (BEFORE) en v1.0.5 (AFTER), gemeten met kwaliteitsmodel v2

MAAT	OFFICIEEL	BEFORE	AFTER	VERSCHIL	ORDEEL
Robuuste kwaliteit	83,5	84,0	83,6	-0,4	slechter
Slechtste regel	68,2	78,5	81,6	+3,1	beter
Nachten	98,9	85,5	82,0	-3,5	slechter
Regelmaat	88,7	93,9	95,0	+1,0	beter
Rust	79,4	82,8	79,3	-3,5	slechter
Eerlijkheid	66,9	85,1	85,9	+0,8	beter
Uitgang na nachten (%)	100,0	65,8	61,5	-4,3	slechter
Nachtrees gevolgd door vroeg	0,00	1,92	1,50	-0,42	beter
Kortste herstel na nachtrees (u)	56,0	43,7	30,9	-12,8	slechter
Begintijdsprong gemiddeld (min)	73	84	71	-13	beter
Losse nachten	0,00	0,15	0,33	+0,18	slechter
Structurele afstand tot officieel	0,0	24,5	24,3	-0,3	beter

Gemiddelden over 60 (BEFORE) en 6 (AFTER) kandidaten. "Beter" en "slechter" gaan over de richting van de maat, niet over een menselijk oordeel.

Wat dit rapport niet zegt

- Dat de nieuwe roosters beter zijn voor de mensen die ze rijden. Niemand heeft ze nog beoordeeld. De drie kandidaatpakketten in hoofdstuk 10 zijn daarvoor gemaakt; na dat oordeel pas volgen verdere wijzigingen aan gewichten of model.
- Dat de menselijke principes wetten zijn. Het is één steekproef: 7 basisroosters, 64 regels, één roosterperiode.
- Iets over gezondheid. "Na nachten liever laat dan vroeg" is hier een voorkeur in het roosterontwerp (*schedule-flow preference*), gemeten aan wat mensen maakten.

De belangrijkste les van deze ronde

Twee keer bleek een onderdeel van de meting minder rust te belonen dan meer: eerst in de solver (H04), daarna in de beoordeling waarop het bijschaven stuurt (H09). Beide keren vond de zoekmachine het gat binnen één meting. De eerste AFTER-meting haalde daardoor maar 5 van de 10 acceptatiepunten. De uitgangswaarde na nachten is nu monotoon in de hersteltijd en dat staat in een test vast. Hoofdstuk 6 beschrijft beide gevallen.

De bron: zeven menselijke roosters

Wat er is ingelezen, gecontroleerd en gemeten

De zeven PDF's van dienstenpakket DDR-BDU-05-10-2026 zijn cel voor cel ingelezen en op twee manieren gecontroleerd: de tijden in de PDF tegen het dienstenpakket (dienst plus weekdag, want een dienstnummer alleen is geen identiteit), en elke cel tegen het officiële rooster in de database. Afwijkingen: 0.

Eén roosterperiode van één standplaats (7 basisroosters, 64 regels). Patronen hieronder zijn waarnemingen in deze steekproef, geen algemene wetten.

De zeven basisroosters

ROOSTER	REGELS	GEWERKT	V / L / N	NACHTREEKSEN	WERKBLOK (D)	EÉN DAGDEEL (%)	SPRONG BEGINTIJD (MIN)	GEM. WEEK INCL. PAUZE	REGELS EXCL. PAUZE
Vroeg DDR-V	12	41	41 / 0 / 0	—	2,2	100,0	81	39:44	26:51–46:37
Vroeg/Laat DDR-VL	10	34	19 / 15 / 0	—	2,1	100,0	62	39:55	27:18–47:22
Laat DDR-L	12	37	0 / 37 / 0	—	1,9	100,0	92	39:59	29:12–48:00
Laat/Nacht DDR-LN	6	22	0 / 16 / 6	6	2,4	100,0	66	39:59	28:48–45:56
Mix DDR-MIX	12	44	15 / 19 / 10	5, 5	2,3	100,0	69	39:51	31:22–40:15
BLM DDR-BLM	6	26	14 / 9 / 3	3	3,3	96,9	63	39:12	23:08–44:02
50+ Mix DDR-50MIX	6	19	11 / 8 / 0	—	1,7	90,2	96	39:51	27:48–47:00

Werkblok: aaneengesloten gewerkte dagen; RES breekt een blok. Sprong begintijd: tussen twee opeenvolgende diensten in hetzelfde dagdeel. Nachtreksen over de regelgrens heen tellen als één reeks.

223

gewerkte dagen in het pakket

98/102

werkblokken met één dagdeel

3 · 5 · 5 · 6

lengtes van de nachtreksen;
geen losse nacht, geen reeks van twee

56 u

kortste herstel na een nachtreeks
(de regel vraagt 46)

Bronbestanden: official-roster-lines.json (elke dag van elke regel), official-features.json, transition-matrix.csv, night-blocks.csv, work-blocks.csv, rest-distribution.csv, rotation-boundaries.csv, off-blocks.csv, profile-priors.json.

Wat de roosters laten zien

Hard tegenover zacht, en twaalf ontwerpprincipes met hun bewijs

Het volledige verslag met tabellen staat in `human-roster-design-principles.md`. Hier de kern.

Wat hard is en wat zacht

HARD: REGEL OF STRUCTUUR	ZACHT: MENSELIJKE VOORKEUR
Dekking: elke dienst precies één keer	Dagdelen clusteren in blokken
Profielgrens: geen vroege dienst in Laat/Nacht	Dagdeelwissels over rust heen
Geplande dagelijkse rust (12 uur)	Nachten in reeksen van drie tot zes
Maximaal 7 aaneengesloten diensten; 7 in een reeks met nachten	Na nachten eerst rust, dan laat
Herstelrust na 3+ nachten (46 uur, bronstatus POTENTIAL)	Ruim herstel na een nachtreeks
RUST-, WR-, CO- en RES-dagen liggen vast in de structuur	Begintijden niet ver laten springen; geen regel opofferen voor het gemiddelde

Niets in de linkerkolom is uit deze roosters afgeleid: dat zijn regels uit de CAO, de Roosterkaders en de roosterstructuur, en die bestonden al in het platform. De rechterkolom komt alleen uit deze roosters.

Twaalf principes

WAARNEMING	BEWIJS IN DE ROOSTERS	PRINCIPE
Een werkblok heeft één dagdeel	98 van de 102 werkblokken	<i>Cluster gelijksoortige diensten</i>
Dagdeelwissels lopen over rust heen	in V/L, L/N en Mix elke wissel na 1–4 vrije dagen	<i>Gebruik rust als scheiding tussen dagdeelfamilies</i>
Geen heen-en-weer op de klok	3 keer op het etiket, alleen in 50+ Mix, waar vroeg en laat qua tijd overlappen	<i>Meet een wissel aan de begintijd, niet aan het etiket</i>
Nachten in reeksen van drie tot zes	reeksen 3, 5, 5, 6; twee lopen over de regelgrens	<i>Bouw nachten als blok; nooit los, liefst niet twee</i>
Na nachten eerst rust, dan laat	alle vier: 2–3 vrije dagen, dan laat; kortste herstel 56 uur	<i>Eerst herstel, dan richting</i>
Begintijden springen, maar niet ver	gemiddeld 73 min, mediaan 60, p90 150	<i>Pas sprongen boven een uur tellen</i>
Rust ruimer dan het minimum	per rooster gemiddeld 3,7–4,8 uur boven de 12 uur	<i>Rust boven het minimum heeft waarde</i>
Blokken kort, vrij in paren	werkblok gemiddeld 2,2 dagen, vastgelegd door RES en rustdagen	<i>Meet wat binnen een blok gebeurt, niet de lengte</i>
Weekenden liggen vast	precies de helft van de regels heeft een vrij weekend	<i>Meten, niet optimaliseren</i>
Eén regel hoeft niet op 40:00	regels binnen een rooster tot 20 uur uit elkaar	<i>Stuur het rooster als geheel; alleen uitschieters tellen</i>
De regelgrens is een gewone dag	zondag → maandag vooral vrij, gewerkt meestal hetzelfde dagdeel	<i>Beoordeel de rotatie als cirkel</i>
Elk profiel een eigen karakter	zie profile-priors.json	<i>Profielkenmerken als zachte verwachting, niet als sjabloon</i>

Wat deze roosters níet laten zien

- Of medewerkers een van deze patronen expliciet waarderen. Daarvoor is de beoordelingsmodus gebouwd (hoofdstuk 11).
- Of dit op andere standplaatsen of in andere roosterperiodes hetzelfde is.
- Een fysiologische onderbouwing. Alles hier is voorkeur in roosterontwerp, gemeten aan wat mensen maakten.

Meten zoals mensen roosteren

Kwaliteitsmodel v2: wat veranderde tegenover v1, en of het de menselijke roosters herkent

Kwaliteitsmodel v1 blijft bestaan en ongewijzigd, zodat eerdere metingen reproduceerbaar blijven. v2 heeft dezelfde onderdelen en gewichten, maar andere definities: klokbewust in plaats van alleen op het etiket, nachten als reeks over de regelgrens heen, uren per rooster in plaats van per regel, en de uitgang na nachten. Elk v2-bestand draagt `learnedFromBenchmark = DDR_BDU_05_10_2026`.

Onderdelen van v2

ONDERDEEL	GEWICHT (%)	WAAROM	DELEN
hours	20	Het basisrooster als geheel hoort op het contractgemiddelde uit te komen; per regel wisselt het mee met de structuur, zoals in de menselijke roosters.	contract, outliers
flow	20	Dagdelen in blokken, wissels over rust heen, geen heen-en-weer van de klok en begintijden die niet ver springen — zoals in de menselijke roosters.	coherence, throughRest, oscillation, penalty, startJitter
rest	15	Rust boven het wettelijk minimum is comfort; herstel na nachten en het vermijden van zware overgangen ook.	surplus, recovery, heavy
nights	20	Nachten in reeksen, liefst van vijf of zes, en daarna eerst rust en dan geen vroege dienst — zoals in alle vier de menselijke nachtreeksen.	blocks, exit
fairness	15	Wie in het ene rooster zit, hoort niet structureel zwaarder belast te zijn dan wie in het andere zit.	nights, shunting, weekend, longDuties
stability	10	Continuïteit: wie zijn rooster kent, merkt een verschoven dagdeel meer dan een ander dienstnummer.	sameDuty, sameDaypart

Herkent v2 wat mensen niet doen?

Voor elk principe is het officiële rooster met een paar ruilen zo slecht mogelijk gemaakt op precies dat principe (de zoekmachine met omgekeerd teken), terwijl het hard geldig bleef. Een goede meting zet het menselijke rooster dan hoger.

Tegenvoorbeelden, gemeten met de definitieve v2

PRINCIPE	RUILEN	V1 ZIET HET	V2 ZIET HET	V2 ONDERDEEL: MENS → TEGENVOORBEELD	V2 ROBUUST
Nachten in reeksen van drie tot zes	4	ja	ja	nachten 98,9 → 58,2	83,5 → 70,5
Na nachten eerst rust, dan laat	3	ja	ja	nachten 98,9 → 74,2	83,5 → 76,5
Geen heen-en-weer van de lichaamsklok	3	ja	ja	regelmaat 88,7 → 75,8	83,5 → 73,0
Begintijden binnen een blok redelijk bij elkaar	4	nee	ja	regelmaat 88,7 → 87,1	83,5 → 82,2
Dagdeelwissels over rust heen	4	ja	ja	regelmaat 88,7 → 74,9	83,5 → 68,0

Daarnaast 30 historische kandidaten van v1.0.3 met een bekend probleem: v2 zet er 30 lager dan het menselijke rooster op nachten of regelmaat. De tegenvoorbeelden worden per meting opnieuw gezocht; vóór H09 miste v1 er twee (`contrastive-check-pre-h09.json`), nu één.

Het officiële rooster scoort onder v2 robuust **83,5** (onder v1: 64,9). Dat is geen doel op zich: een meting die het menselijke rooster onterecht laag zet, stuurt de zoekmachine weg van wat mensen maken. Na H09 is dat 0,7 punt lager dan in de eerste versie van v2; hoofdstuk 6 legt uit waarom dat is geaccepteerd.

Wat er aan de zoekmachine veranderde

Overgangstabel in de solver, bewaking bij het bijschaven, en wat is afgewezen

De zoekmachine heeft twee stappen die ertoe doen: de CP-SAT-solver bouwt een startrooster, het bijschaven (ruilen en herstarten) verbetert dat op de kwaliteitsmaat. Het bijschaven is de grootste hefboom, en stuurt nu op v2. De solver kreeg alleen wat hij goed kan uitdrukken.

De uitgang na nachten in de solver

Strafpunten na een nachtdienst, klassiek tegenover menselijk ritme

NA NACHT	KLASSIEK	MENSELIJK RITME (1.0.5)
direct vroeg	6	6
direct laat	3	5
één vrije dag, vroeg	3	4
één vrije dag, laat	1	3
twee vrije dagen, vroeg	0	2
twee vrije dagen, laat	0	0

Strikt dalend met de rust, en vroeg steeds duurder dan laat bij evenveel vrije dagen (H05). Alle vier de menselijke nachtreeksen eindigen op twee of drie vrije dagen en dan laat. Alleen in de adaptieve zoekmachine; de klassieke is ongewijzigd.

Afgewezen: de begintijdsprong in de solver

Een term die sprongen in begintijd binnen een dagdeel in de solver straffe, maakte nachten en eerlijkheid slechter. Hij staat erin, maar met gewicht 0: de begintijden worden alleen door het bijschaven op v2 bewaakt.

A/B in de solver, 3 zaadwaarden, 40 s (H03, gemeten met v2 van dat moment)

MAAT	ZONDER TERM	MET TERM	VERSCHIL
Robuust	85,6	81,3	-4,3
Nachten	92,8	82,6	-10,2
Eerlijkheid	87,1	79,9	-7,2
Vroeg na nachten	0,7	1,0	+0,3
Kortste herstel (u)	42,5	43,5	+1,0
Sprong begintijd (min)	75,0	49,7	-25,3

A/B in de solver: nachtingang uit en aan, 3 zaadwaarden, 40 s (H05)

MAAT	KLASSIEK	MENSELIJK RITME	VERSCHIL
Robuust	86,0	85,5	-0,5
Nachten	91,0	93,3	+2,3
Eerlijkheid	81,9	84,8	+2,9
Vroeg na nachten	1,0	0,0	-1,0
Kortste herstel (u)	50,3	25,7	-24,6
Sprong begintijd (min)	73,7	71,3	-2,3

Drie runs per opstelling tonen alleen een richting: CP-SAT met 8 zoekdraden is niet deterministisch. Het kortste herstel van 12–13 uur in twee runs komt uit korte reeksen die de solver niet oplost; dat bleef over voor het bijschaven — en dat ging mis tot H09.

Bewaking bij het bijschaven

Het bijschaven mag eerlijkheid hooguit 0,5 punt en uren en rust hooguit 1 punt laten zakken ten opzichte van het startrooster; elk punt daarboven kost 10 in de rangschikking, en een reparatie die het doet, wordt afgewezen (H07). Dat is een bewaking tegenover de start van het bijschaven, niet tegenover v1.0.4: zie hoofdstuk 9.

Versies

ONDERDEEL	VERSIE	BESTAND
Zoekmachine	adaptive-1.0.5	configs/optimizer-config-v1.0.5.json
Kwaliteitsmodel	quality-model-v2	configs/quality-model-v2.json
Vorige zoekmachine (bevroren)	adaptive-1.0.4	configs/optimizer-config-v1.0.4.json
Vorig kwaliteitsmodel (bevroren)	quality-model-v1	configs/quality-model-v1.json

Ontwikkelog

Elke wijziging met reden en gemeten effect, ook wat niet werkte

Wijzigingen H01–H09

NR	WAT	GEMETEN EFFECT	UITKOMST
H01	quality-model.ts / quality-evaluator.ts — kwaliteitsmodel v2 Nieuwe versie naast v1 (v1 blijft volledig rekenbaar). Gewichten van de onderdelen ongewijzigd; veranderd is wat vier onderdelen meten: uren per regel alleen buiten de menselijke band ($\pm 10:30$), regelmaat als samenhang + wissels via rust + heen-en-weer op de klok + overgangsstraf + begintijdsprong (reekslengte eruit), overgangen op de klok (<3 uur verschuiving telt hooguit 1 punt), nachten als reekswaarde naar lengte + uitgang na de reeks.	Officieel onder v2: robuust 84,2, regelmaat 90,1, uren 83,9. Contrastieve toets (contrastive-check.json): v2 ziet alle vijf de opzettelijk bedorven varianten van het officiële rooster op het aangetaste onderdeel én zet het menselijke rooster steeds hoger; v1 zag springende begintijden niet en verkoos een variant met vroege diensten na nachten boven het menselijke rooster. Alle 29 v1.0.3-kandidaten met losse nachten of zware overgangen scoren onder v2 lager dan het menselijke rooster op nachten of regelmaat.	behouden; CURRENT_QUALITY_MODEL = v2
H02	quality-evaluator.ts — stabiliteit per regel op de klok In v2 telt een opeenvolging als stabiel bij hetzelfde dagdeel óf minder dan 3 uur verschuiving in begintijd.	Slechtste officiële regel 47,4 $\rightarrow$ 70,8 (nog steeds 50+ Mix regel 2, nu door een week van 30:14 — structureel); robuust officieel 78,4 $\rightarrow$ 84,2.	behouden
H03	cpsat_roster.py — begintijdsterm (startJitter) Nieuwe zachte term: per minuut sprong in begintijd boven 60 minuten, tussen opeenvolgende diensten in hetzelfde dagdeel, gewicht 1 (kleinste gehele waarde).	A/B op de ruwe solveruitkomst, 3 zaadwaarden $\times$ 40 s (solver-ab-uit-aan.json): sprong gemiddeld 75 $\rightarrow$ 50 en p90 179 $\rightarrow$ 106 minuten, maar robuust 85,6 $\rightarrow$ 81,3, nachten 92,8 $\rightarrow$ 82,6, eerlijkheid 87,1 $\rightarrow$ 79,9, en in één run een losse nacht. Stijver dan de mensen zelf (p90 150).	verworpen: gewicht op 0. De term blijft in de code, uit, met deze meting als reden. Begintijden worden alleen via het bijschaven (model v2) verbeterd.
H04	roster-quality-config.ts — nachtitgang voor CP-SAT, eerste versie Nacht $\rightarrow$ laat over één vrije dag 1 $\rightarrow$ 3 strafpunten, nacht $\rightarrow$ vroeg over twee vrije dagen 2.	In één van drie runs een nachtreeks met 13,1 uur herstel: 'nacht, één vrije dag, laat' kostte nu evenveel als 'nacht, direct laat' (beide 3), dus de solver maakte geen onderscheid meer.	vervangen door H05; de fout staat in solver-ab-nacht.json
H05	roster-quality-config.ts — nachtitgang, monotone tabel Na nachten: direct vroeg 6, direct laat 3 $\rightarrow$ 5; één vrije dag vroeg 3 $\rightarrow$ 4, laat 1 $\rightarrow$ 3; twee vrije dagen vroeg 2, laat 0. Strikt dalend met de rust, vroeg steeds duurder dan laat. Alleen in de adaptieve zoekmachine (humanRhythm), niet in de klassieke.	Gelijk-op gemeten in dezelfde sessie, 3 runs met en 3 zonder (solver-ab-uit-nacht.json): robuust 86,0 $\rightarrow$ 85,5, nachten 91,0 $\rightarrow$ 93,3, eerlijkheid 81,9 $\rightarrow$ 84,8, vroeg na nachten 1,0 $\rightarrow$ 0 per kandidaat. Het slechtste herstel in een run (12–13 uur na een korte reeks) wordt hier niet opgelost. Correctie: een eerder genoemde vergelijking 'zes tegen zes' voegde runs met de tabel van H04 en die van H05 samen en is daarom niet gebruikt.	behouden. Kanttekening: CP-SAT met 8 zoekdraden is niet deterministisch; dezelfde zaadwaarden gaven tussen twee metingen robuust 83,7/86,0/87,1 tegen 88,5/85,5/83,9. Drie runs tonen alleen een richting; de AFTER-meting met 20 runs is de toets.
H06	rhythm-metrics.ts — uitgangswaarde na nachten met herstelrust Een late dienst na een nachtreeks telt voluit alleen als de herstelrust uit de regel (NIGHT_SEQUENCE_RECOVERY, 46 uur) is gehaald; sneller telt half.	Officieel ongewijzigd (alle uitgangen $\geq$ 56 uur, uitgang 100).	behouden

NR	WAT	GEMETEN EFFECT	UITKOMST
H07	adaptive/config.ts + engine.ts — bewaking van eerlijkheid, uren en rust Bijschaven en reparatie mogen eerlijkheid hooguit 0,5 punt, uren en rust hooguit 1 punt laten zakken ten opzichte van de start; daarboven kost elk punt 10 in de rangschikking van het bijschaven en wordt een reparatie afgewezen.	Rookproef: een reparatie die de rangschikking 82,3 → 85,4 bracht, werd afgewezen omdat eerlijkheid 0,6 zakte. Dat is de bedoeling, en het kost aantoonbaar kwaliteit elders.	behouden
H08	scripts/benchmark/evaluate.ts — modelkeuze De v1.0.4-benchmarkevaluatie rekent standaard met model v1 en schrijft de werkelijk gebruikte versie weg; --model v2 rekent met het nieuwe.	Geen verschil in de opgeslagen v1.0.4-uitkomsten; de fout is voorkomen voordat hij optrad.	behouden
H09	quality-model.ts + rhythm-metrics.ts — uitgang na nachten en de grens tussen etiket en echte wissel Uitgang na een nachtreeks: eerst herstel, dan richting. Onder de herstelrust uit de regel (46 uur) is elke uitgang 0; daarboven laat of nacht 1, vroeg 0,25, vroeg na 72 uur 0,5 (was: laat altijd minstens 0,5, vroeg onder 72 uur 0). Een wissel geldt als alleen een ander etiket als de begintijd hooguit 60 minuten verschuift (was: minder dan 180), voor strafpunten, regelstabiliteit en heen-en-weer.	Officieel robuust 84,2 → 83,5 en regelmaat 90,1 → 88,7: in 50+MIX regel 4 telt vroeg 10:08 → laat 12:19 → rust → vroeg 08:00 nu als (mild) heen-en-weer, en twee voorwaartse wissels van 126 en 131 minuten niet meer als stabiel. Een richtingsafhankelijke grens (voorwaarts 180, achterwaarts 60) liet het officiële rooster ongemoeid, maar steunde op twee plus twee gevallen uit één steekproef en is daarom niet gekozen. Drie nieuwe tests leggen vast dat de uitgangswaarde nooit daalt met meer herstel en dat het BLM-patroon zwaar telt.	behouden; de AFTER-meting is met deze definities opnieuw gedraaid (docs/optimizer-benchmark/human). De eerste meting blijft bewaard als ontwikkelmeting en is met de definitieve v2 opnieuw doorgerekend (analysis-dev1-final-v2.json).

H09: de eerste AFTER-meting

De eerste volledige AFTER-meting (20 runs, docs/optimizer-benchmark/human-dev1) haalde 5 van de 10 acceptatiepunten. De diagnose per basisrooster wees naar één plek:

	BEFORE (v1.0.4)	EERSTE AFTER
Kandidaten met een nachtitgang onder 36 uur	17	28
Uitgangen onder de herstelregel in BLM	9	26
BLM-regels met laat direct gevolgd door vroeg	0	15

Twee meetdefinities die ik zelf te ruim had gekozen, verklaarden dat:

- **Etiket of echte wissel.** Een wissel gold als "alleen een ander etiket" bij minder dan drie uur verschuiving. Het bijschaven liet daardoor in BLM een laat van 09:47 gratis volgen door een vroeg van 07:22 (13,2 uur rust). De enige officiële directe etiketwissels verschuiven 19 en 41 minuten. De grens is nu een uur, gelijk aan de vrije begintijdsprong.
- **Uitgang na nachten.** Nacht-vrij-laat (32 uur) scoorde 0,5, nacht-vrij-vrij-vroeg (48 uur) 0. De solver had dat goed (H05); het bijschaven draaide het terug. Nu eerst herstel, dan richting; een test legt vast dat de waarde nooit daalt bij meer herstel.

Prijs: het officiële rooster verliest 0,7 punt robuust, omdat in 50+ Mix vroeg 10:08 → laat 12:19 → rust → vroeg 08:00 nu als mild heen-en-weer telt. Een grens per richting (vooruit 180, achteruit 60) had dat voorkomen, maar steunde op twee plus twee gevallen uit één steekproef; die is daarom niet gekozen.

Alle getallen in dit rapport zijn met de definitieve v2 berekend, ook die van de eerste AFTER-meting en van v1.0.4: de ruwe kandidaatroosters zijn bewaard en opnieuw doorgerekend. De uitkomst van de eerste meting onder de eerste definities staat in analysis-dev1-pre-h09.json .


Een correctie op mijn eigen tussenstand

Bij H05 noemde ik eerst een vergelijking van "zes tegen zes" runs. Daarin zaten runs met de tabel van H04 en die van H05 door elkaar; die vergelijking is niet gebruikt. De cijfers in hoofdstuk 5 komen uit één sessie, drie runs met en drie zonder.

BEFORE en AFTER

Dezelfde meting voor en na, met de eerste AFTER-meting ernaast

BEFORE zijn de 20 runs van v1.0.4 (60 kandidaten), gemaakt op dezelfde gegevens en dezelfde machine en hier met v2 doorgerekend. Dat is hetzelfde als opnieuw draaien, zonder de ruis van een nieuwe CP-SAT-meting. **AFTER** zijn 2 nieuwe runs van v1.0.5 met dezelfde verdeling over strategieën (10 Evenwichtig, 5 Rust, 5 Eerlijke lasten), 6 kandidaten.



Gemiddelden per onderdeel. Goud: het officiële rooster; lichtblauw: v1.0.4; donkerblauw: v1.0.5. Continuïteit ontbreekt: het officiële rooster is daar per definitie 100.

Alle maten, gemeten met kwaliteitsmodel v2

MAAT	OFFICIEEL	BEFORE	EERSTE AFTER	AFTER	AFTER MIN-MAX	Δ AFTER – BEFORE	OORDEEL
Robuuste kwaliteit	83,5	84,0	84,4	83,6	80,7–85,7	–0,4	slechter
Kwaliteit zonder continuïteit	84,7	87,8	88,4	86,8	85,0–87,9	–1,0	slechter
Slechtste regel	68,2	78,5	77,4	81,6	73,3–88,1	+3,1	beter
Regelmaat	88,7	93,9	94,4	95,0	93,7–96,6	+1,0	beter
Nachten	98,9	85,5	89,7	82,0	73,4–85,8	–3,5	slechter
Rust	79,4	82,8	80,1	79,3	77,8–81,3	–3,5	slechter
Uren	83,9	89,7	89,6	89,6	89,1–89,8	–0,1	slechter
Eerlijkheid	66,9	85,1	85,6	85,9	82,4–86,9	+0,8	beter
Continuïteit	100,0	59,6	60,3	58,7	55,7–61,9	–0,9	slechter
Heen-en-weer (op de klok)	2,00	0,17	0,07	0,00	0,00–0,00	–0,17	beter
Losse nachten	0,00	0,15	0,17	0,33	0,00–1,00	+0,18	slechter
Reeksen van twee nachten	0,00	0,20	0,35	0,33	0,00–2,00	+0,13	slechter
Waarde nachtreeksen (%)	98,4	93,9	93,2	90,8	77,4–94,7	–3,1	slechter
Nachtreeks gevolgd door vroeg	0,00	1,92	0,63	1,50	1,00–2,00	–0,42	beter
Kortste herstel na nachtreeks (u)	56,0	43,7	40,2	30,9	27,4–33,0	–12,8	slechter
Uitgang na nachten (%)	100,0	65,8	81,4	61,5	50,0–75,0	–4,3	slechter
Samenhang in werkblokken (%)	97,8	98,9	98,6	98,5	97,8–99,5	–0,4	slechter
Gemiddeld werkblok (dagen)	2,19	2,19	2,19	2,19	2,19–2,19	0,00	gelijk

MAAT	OFFICIEEL	BEFORE	EERSTE AFTER	AFTER	AFTER MIN-MAX	Δ AFTER – BEFORE	OORDEEL
Dagdeelwissels via rust (%)	82,8	94,7	93,2	94,3	90,9–96,7	–0,4	slechter
Begintijdsprong gemiddeld (min)	73	84	73	71	62–78	–13	beter
Begintijdsprong p90 (min)	150	204	169	170	153–210	–34	beter
Zwaarste overgang (punten)	4,00	0,98	2,05	1,00	1,00–1,00	+0,02	slechter
Regels met zware overgang	2,00	0,03	0,47	0,00	0,00–0,00	–0,03	beter
Structurele afstand tot officieel	0,0	24,5	19,1	24,3	23,2–26,1	–0,3	beter

Eerste AFTER: de meting vóór H09, met dezelfde definitieve v2 doorgerekend. Het oordeel vergelijkt AFTER met BEFORE.

Acceptatie (\$81) en bewaking (\$75)

EIS	GEHAALD
0 harde overtredingen, volledige dekking, 0 profielovertredingen	ja
Minder heen-en-weer	ja
Minder losse nachten	nee
Langere, samenhangender werkblokken	nee
Beter herstel na nachten	nee
Stabieler begintijden	ja
Minder zware slechtste overgang	nee
Eerlijkheid niet verder achteruit (marge 0,5)	ja
Uren niet noemenswaardig achteruit (marge 1)	ja
Rust niet noemenswaardig achteruit (marge 1)	nee

Hard: 6 AFTER-kandidaten, allemaal hard geldig; ja; hoogstens 0 niet toegewezen diensten en 0 profielovertredingen per kandidaat. "Minder" en "beter" betekenen: het gemiddelde over de kandidaten verschuift de goede kant op.

Hoofdstuk 8

Per basisrooster

Waar de uitkomst per profiel ligt, en waar de uitschieters zitten

Een gemiddelde over het hele pakket kan één profiel verbergen dat achteruitgaat. In de eerste AFTER-meting was dat BLM. Per rooster: officieel · BEFORE · **AFTER** (gemiddelde over de kandidaten).

ROOSTER	NACHTREEKS (%)	KORTSTE HERSTEL (U)	VROEG NA NACHTEN	HEEN-EN-WEER	SPRONG (MIN)	ZWAARSTE OVERGANG
50+ Mix	—	—	0,00 · 0,00 · 0,00	2,00 · 0,03 · 0,00	96 · 110 · 110	4,0 · 0,0 · 0,0
BLM	90 · 94 · 85	79 · 52 · 43	0,00 · 0,78 · 1,00	0,00 · 0,00 · 0,00	63 · 83 · 73	1,0 · 0,5 · 0,3
Laat	—	—	0,00 · 0,00 · 0,00	0,00 · 0,00 · 0,00	92 · 103 · 77	0,0 · 0,0 · 0,0
Laat/Nacht	100 · 95 · 84	56 · 62 · 62	0,00 · 0,00 · 0,00	0,00 · 0,00 · 0,00	66 · 78 · 79	0,0 · 0,4 · 0,3
Mix	100 · 93 · 96	59 · 50 · 46	0,00 · 1,13 · 0,50	0,00 · 0,10 · 0,00	69 · 63 · 46	1,0 · 0,7 · 0,8
Vroeg	—	—	0,00 · 0,00 · 0,00	0,00 · 0,00 · 0,00	81 · 67 · 59	0,0 · 0,0 · 0,0
Vroeg/Laat	—	—	0,00 · 0,00 · 0,00	0,00 · 0,03 · 0,00	62 · 111 · 91	0,0 · 0,2 · 0,5

Uitschieters, geteld over alle kandidaten

	OFFICIEEL	BEFORE	AFTER
Kortste herstel na nachten, per kandidaat	<36: 0 36-45: 0 46-55: 1 ≥56: 0	<36: 17 36-45: 0 46-55: 37 ≥56: 6	<36: 6 36-45: 0 46-55: 0 ≥56: 0
Nachttuitgangen onder de herstelregel (46 u)	—	DDR-BLM: 9 DDR-LN: 8	DDR-MIX: 2 DDR-BLM: 2 DDR-LN: 2
Regels met een zware overgang (op etiket)	DDR-50MIX · LE: 2	DDR-BLM · NRE: 2	—
Nachtreeksen van één of twee	—	DDR-MIX · 2: 10 DDR-MIX · 1: 7 DDR-BLM · 2: 2 DDR-LN · 1: 1 DDR-BLM · 1: 1	DDR-BLM · 2: 2 DDR-LN · 1: 2

Zware overgang hier op het etiket (strafpunten ≥ 3), zonder klokcorrectie; daardoor telt het officiële 50+ Mix twee keer mee met laat → vroeg van 19 en 41 minuten. LE = laat direct gevolgd door vroeg; NRE = nacht, één vrije dag, vroeg.

Regressies en wat open blijft

Alles wat na de ijking slechter is, of niet is opgelost

Gemiddeld slechter dan v1.0.4

MAAT	BEFORE	AFTER	VERSCHIL	OFFICIEEL
Robuuste kwaliteit	84,0	83,6	-0,4	83,5
Kwaliteit zonder continuïteit	87,8	86,8	-1,0	84,7
Nachten	85,5	82,0	-3,5	98,9
Rust	82,8	79,3	-3,5	79,4
Uren	89,7	89,6	-0,1	83,9
Continuïteit	59,6	58,7	-0,9	100,0
Losse nachten	0,15	0,33	+0,18	0,00
Reeksen van twee nachten	0,20	0,33	+0,13	0,00
Waarde nachtreeksen (%)	93,9	90,8	-3,1	98,4
Kortste herstel na nachtreeks (u)	43,7	30,9	-12,8	56,0
Uitgang na nachten (%)	65,8	61,5	-4,3	100,0
Samenhang in werkblokken (%)	98,9	98,5	-0,4	97,8
Dagdeelwissels via rust (%)	94,7	94,3	-0,4	82,8
Zwaarste overgang (punten)	0,98	1,00	+0,02	4,00

Elke regel hier is een echte achteruitgang op die maat, ook als hij klein is. Een maat waarop v1.0.4 al beter scoorde dan het officiële rooster (bijvoorbeeld samenhang in werkblokken), kan iets zakken zonder van de referentie weg te bewegen; dat staat erbij, niet in plaats van.

Bekende beperkingen

- **Eén steekproef.** Alle zachte principes komen uit één roosterperiode van één standplaats.
- **Ruis.** CP-SAT met 8 zoekdraden is niet deterministisch; dezelfde zaadwaarden gaven tussen twee metingen robuust ±2–3. Twintig runs per meting dempen dat, maar een verschil van een paar tienden is geen bewijs.
- **De bewaking is relatief.** Eerlijkheid, uren en rust worden bewaakt tegenover de start van het bijschaven, niet tegenover v1.0.4. Een solver die een ander startpunt kiest, kan een onderdeel dus meer laten zakken dan de marge.
- **Het officiële rooster is geen plafond.** Op regelmaat en uren scoren de gegenereerde kandidaten al hoger dan het officiële rooster; op nachten en uitgang na nachten lager. Dat hoger is niet "menselijker": het is hoe de maat telt.
- **Geen menselijk oordeel.** Alles in dit rapport is meting. Het oordeel komt uit hoofdstuk 10 en 11.

De drie kandidaatpakketten

Ter beoordeling door de Roostercommissie

NOG NIET GEGENEREERD — draai `npm run human-benchmark:final -- generate`.

Hoe de beoordeling werkt

Oordeel per regel en voorkeur tussen kandidaten; wat ermee gebeurt

Onder elke roosterregel in de simulatie staat *Regel beoordelen*: Goed, Twijfel of Slecht, met redenen die aansluiten op wat het model meet (goede flow, goede nachtreeks, goed herstel, goede uren; heen-en-weer, losse nacht, reeks van twee nachten, slecht herstel, grote sprong in begintijd, uitschieter in uren, oneerlijk, zware weekenden) en een vrije toelichting. Op de vergelijkingspagina staat per paar kandidaten *Welke rijdt menselijker?* met redenen als betere flow, betere nachtreksen, beter herstel, eerlijker, minder vreemde overgangen.

Wat er per oordeel wordt bewaard

VELD	WAAROM
kandidaat, basisrooster, regel	waar het oordeel over gaat; de regel moet echt in de kandidaat bestaan
oordeel, redenen, toelichting	de redenen zijn een vaste lijst; een onbekende reden wordt geweigerd
kwaliteitsmodel- en zoekmachineversie	zonder versies is later niet te zeggen waarover het oordeel ging
wie en wanneer	personeelsnummer en tijdstip; namen staan achter een aparte permissie
auditregel	kandidaat.menselijk-oordeel en kandidaat.menselijke-voorkeur

Een oordeel verandert niets automatisch: geen gewicht, geen model, geen productie-instelling. Het is grondstof voor de volgende ijking, die pas begint na jullie feedback.

Reproduceerbaarheid en controles

Welke opdracht welk bestand maakt, en wat de tests zeggen

OPDRACHT	MAAKT
<code>npm run human-benchmark:extract</code>	officiële kenmerken, CSV's, profielverwachtingen
<code>npm run human-benchmark:contrastive</code>	<code>contrastive-check.json</code>
<code>npm run human-benchmark:solver-ab</code>	<code>solver-ab-*.json</code>
<code>npm run verify:optimizer-benchmark -- run --phase human ...</code>	<code>docs/optimizer-benchmark/human/run-*.json</code> (ruwe kandidaatroosters)
<code>npm run human-benchmark:analyse</code>	<code>analysis-before-after.json</code>
<code>npm run human-benchmark:analyse -- --after human-dev1 --out analysis-dev1-final-v2.json</code>	de eerste AFTER-meting met de definitieve v2
<code>npm run human-benchmark:final -- generate export</code>	de drie kandidaten, <code>final-candidates/</code>
<code>npm run config:write</code>	<code>configs/quality-model-v2.json</code> , <code>configs/optimizer-config-v1.0.5.json</code>
<code>npm run report:human</code> en <code>report:human-pdf</code>	dit rapport

Controles nog niet vastgelegd (`checks.json` ontbreekt).