



VERSIE 1.0.4 · OPTIMIZER

De zoekmachine gemeten, verbouwd en opnieuw gemeten

Wat een roosterpakket van v1.0.3 opleverde, wat er aan de zoekmachine is veranderd, en wat dezelfde meting daarna liet zien — inclusief wat niet werkte.

Standplaats DDR · dienstenpakket DDR-BDU-05-10-2026-V1

20 BEFORE-runs · 20 AFTER-runs
120 kandidaten beoordeeld
kwaliteitsmodel —

Inhoud

1	Managementsamenvatting	Wat er is gemeten, wat het opleverde en wat het besluit is
2	Testcondities	Wat aan beide kanten gelijk was, en hoe dat is afgedwongen
3	De BEFORE-meting	Wat de v1.0.3-machine opleverde, met spreiding
4	Het officiële rooster als ijkpunt	Wat menselijk gemaakte structuur oplevert op dezelfde maten
5	Architectuur van de zoekmachine	De keten van genereren tot selecteren, en wat waar wordt beslist
6	Het kwaliteitsmodel	Waaruit het oordeel bestaat en waarom het per regel meet
7	De zoekstrategie	Budgetten, variatie, de kwaliteitspoort en de stopvoorwaarden
8	Wijzigingen in code en configuratie	Welke onderdelen nieuw zijn, welke zijn aangepast en wat onaangeroerd bleef
9	Gewichten en drempels	Welke getallen de zoektocht sturen en wat elke wijziging opleverde
10	De AFTER-meting	Dezelfde benchmark, met de nieuwe zoekmachine
11	BEFORE tegenover AFTER	De volledige vergelijking, inclusief wat achteruitging
12	Per basisrooster en profiel	Of de winst overal zit, of ergens iemand ervoor betaalt
13	Laat en Nacht in detail	Nachtreeksen, herstel, verdeling en de absolute profieltoets
14	Rekentijd	Wat het kost, waar het heen gaat en waar de opbrengst afvlakt
15	Zoekefficiëntie	Hoeveel werk er is verzet en hoeveel daarvan iets opleverde
16	Wat niet werkte	Aanpakken die zijn geprobeerd, gemeten en verworpen
17	Regressies en risico's	Wat slechter werd, wat hard is getoetst en wat er mis kan gaan
18	Testresultaten	Welke tests zijn gedraaid en wat ze zeiden
19	Bekende beperkingen	Waar deze meting niets over zegt
20	Fouten opsporen	Van kandidaat terug naar de beslissing die hem maakte
21	Reproduceerbaarheid	Hoe elke meting opnieuw te draaien is
22	Conclusie en besluit	Wat is aangetoond, wat niet, en wat er nu gebeurt

Dit rapport is gegenereerd uit de ruwe meetgegevens in `docs/optimizer-benchmark/`. Elk getal in dit document komt uit die bestanden; er staan geen voorbeeldwaarden in. Wie een cijfer wil natrekken, vindt onder hoofdstuk 21 welke opdracht het oplevert.

Managementsamenvatting

Wat er is gemeten, wat het opleverde en wat het besluit is

De v1.0.3-zoekmachine leverde per opdracht één CP-SAT-oplossing per kandidaat. De v1.0.4-machine zoekt breder: meerdere vertrekpunten, een onafhankelijke kwaliteitsmeting van elke kandidaat, gericht repareren en bijschaven met ruildiensten. Dit hoofdstuk zegt in het kort wat dat opleverde.

77,0

robuuste kwaliteit BEFORE (gemiddeld over 60 kandidaten)

79,4

robuuste kwaliteit AFTER (gemiddeld over 60 kandidaten)

+2,4

verschil in robuuste kwaliteit

+7,9

verschil op de slechtste roosterregel

Wat beter werd en wat niet

Vooruit op het gemiddelde: Kwaliteit zonder continuïteit, Robuuste kwaliteit (pakket + slechtste regel), Uren, Regelmaat, Rust, Nachten, Slechtste regel.

Achteruit op het gemiddelde: Eerlijkheid. Hoofdstuk 11 en 17 laten zien hoeveel en waarom.

De kernmaten in één oogopslag

MAAT	OFFICIEEL	BEFORE GEM.	AFTER GEM.	Δ GEM.	Δ MEDIAAN	Δ SLECHTSTE
Robuuste kwaliteit (pakket + slechtste regel)	64,9	77,0 ± 2,3	79,4 ± 0,8	+2,4	+1,8	+5,9
Kwaliteit zonder continuïteit	78,6	83,5 ± 1,2	84,7 ± 0,7	+1,3	+1,2	+2,6
Slechtste regel	15,6	55,2 ± 7,7	63,1 ± 2,2	+7,9	+4,3	+14,0
Uren	70,3	76,3 ± 0,3	76,9 ± 0,3	+0,6	+0,7	+0,4
Regelmaat	75,7	79,8 ± 1,2	80,4 ± 1,0	+0,7	+0,8	+0,7
Rust	76,7	77,0 ± 3,6	82,8 ± 3,1	+5,8	+6,4	+7,7
Nachten	100,0	96,9 ± 4,8	98,1 ± 3,0	+1,2	0,0	+5,3
Eerlijkheid	66,9	86,4 ± 3,5	85,1 ± 2,9	-1,4	0,0	+2,2
Continuïteit	100,0	59,5 ± 2,8	59,6 ± 3,4	+0,1	0,0	-1,2

Alle kandidaten van beide fasen, niet alleen de beste. De kolom Officieel is het menselijke rooster met hetzelfde model gemeten: een ijkpunt, geen norm.

Hoe vaak wint de nieuwe machine

Per run telt voor de Roostercommissie de beste kandidaat. Leg de runs van beide fasen op volgorde naast elkaar, dan wint AFTER 20 van de 20 vergelijkingen. Vergelijk elke AFTER-run met elke BEFORE-run, dan is de kans dat de nieuwe machine wint 93%.

Wat het kost

Een opdracht duurde in de BEFORE-meting gemiddeld 3 min 42 s en in de AFTER-meting 4 min 37 s. Daarvoor onderzocht de machine per run gemiddeld 132.827 varianten in plaats van één oplossing per kandidaat.

Besluit: de adaptieve zoekmachine gaat mee als standaard, met de kanttekeningen uit hoofdstuk 17. De terugvalschakelaar naar v1.0.3 blijft bestaan.

Dit rapport claimt nergens dat de machine betere roosters maakt dan roostermakers. Het officiële rooster is met hetzelfde model gemeten en dient als ijkpunt voor wat menselijk gemaakte structuur oplevert; verschillen daarmee zeggen iets over de maat, niet over vakmanschap.

Hoofdstuk 2

Testcondities

Wat aan beide kanten gelijk was, en hoe dat is afgedwongen

Een vergelijking gaat alleen over de zoekmachine als al het andere gelijk blijft. Dit hoofdstuk legt vast wat er aan beide kanten hetzelfde was, en hoe dat is afgedwongen.

Vastgelegde condities

WAT	BEFORE	AFTER	GELIJK?
Dienstenpakket	DDR-BDU-05-10-2026-V1	DDR-BDU-05-10-2026-V1	gelijk
Standplaats	DDR	DDR	gelijk
Roosterstructuur	e2611821d375c42d	e2611821d375c42d	gelijk
Invoergegevens	7ff588d3e53e4f87	7ff588d3e53e4f87	gelijk
Profielconfiguratie (hash)	e73a3bab43b5	e73a3bab43b5	gelijk
Regelbestand (hash)	6dd5d1619bd3	6dd5d1619bd3	gelijk
Regelversie	2026.1-ca0-2024-2025-transcribed (71 regels)	2026.1-ca0-2024-2025-transcribed (71 regels)	gelijk
Juridische status	LEGAL_RULESET_NOT_CURRENTLY_VERIFIED	LEGAL_RULESET_NOT_CURRENTLY_VERIFIED	gelijk
Solverscript (hash)	9a76e9638cc0	4e7a040e34e1	VERSCHILT
Optimizerconfiguratie (hash)	c3d50ebc3e0d	c3d50ebc3e0d	gelijk

Het solverscript hoort hier te verschillen: daar zit de vastzetting voor de gerichte reparatie in, en dat is het experiment. De optimizerconfiguratie in dit overzicht is die van de klassieke zoekmachine; die is ongewijzigd gebleven, want de adaptieve machine heeft zijn eigen configuratie (configs/optimizer-config-v1.0.4.json, hoofdstuk 7 en 9). De benchmark weigert te starten wanneer de gegevens, de profielen, het regelbestand of de machine afwijken; die vingerafdruk is in beide fasen gelijk.

De machine

ONDERDEEL	WAARDE
Processor	Intel(R) Core(TM) i7-14700K
Logische kernen	28
Werkgeheugen	63,8 GB
Besturingssysteem	Windows_NT 10.0.26200 x64
Node	v24.17.0
Python	3.11.1
OR-Tools	9.15.6755
Solverdraden	8

Vastgelegde code

BEFORE draaide op commit e2b20918d703 , AFTER op commit e2b20918d703 (met niet-vastgelegde wijzigingen). De v1.0.3-machine blijft bereikbaar via de schakelaar NS_OPTIMIZER_ENGINE=legacy ; hoofdstuk 21 beschrijft hoe een meting exact wordt herhaald.

Wat niet is veranderd: de harde regels, de profielgrenzen, de eindvalidatie, de publicatiepoort en de juridische status van het regelbestand. Een kandidaat die de validatie niet haalt, komt in beide fasen niet in de uitkomst terecht.

De BEFORE-meting

Wat de v1.0.3-machine opleverde, met spreiding


De BEFORE-meting is gedraaid met de v1.0.3-zoekmachine, vóór er een regel aan de optimalisatie was veranderd. Zonder die meting zou elke latere uitspraak over verbetering een mening zijn.

De BEFORE-meting per strategie

STRATEGIE	RUNS	KANDIDATEN	ROBUUST GEM.	ROBUUST MEDIAAN	LAAGSTE	HOOGSTE	REKENTIJD GEM.
BALANCED	10	30	77,0	78,1	71,4	79,1	3 min 45 s
REST_QUALITY	5	15	78,5	78,5	77,3	79,6	3 min 14 s
FAIR_BURDEN	5	15	75,6	75,8	71,8	79,7	4 min 03 s

Waarom meer dan één run

CP-SAT met meerdere zoekdraden en een tijdslimiet levert bij identieke invoer niet elke keer hetzelfde rooster op. In de BEFORE-meting liep de robuuste kwaliteit van 71,4 tot 79,7 over 60 kandidaten. Eén run had dus elk verhaal kunnen ondersteunen; daarom staat overal in dit rapport de spreiding erbij.



Verdeling van de robuuste kwaliteit over alle kandidaten van beide fasen. De robuuste kwaliteit weegt het totaalcijfer met de slechtste roosterregel en met uitschieters, zodat één slecht rooster niet wegvalt tegen zes goede.

Wat de BEFORE-meting bewaart

Per run is het ruwe resultaat bewaard: alle toewijzingen van elke kandidaat, de solverstatistiek, de validatie-uitkomst, de zaadwaarde, de rekentijd en het geheugengebruik. De kwaliteitsmaten zijn daar achteraf uit berekend. Dat is bewust: wordt er later een fout in een maat gevonden, dan kan die op beide fasen opnieuw worden toegepast zonder de solver nog een keer te draaien.

Het officiële rooster als ijkpunt

Wat menselijk gemaakte structuur oplevert op dezelfde maten

Het officiële rooster is met precies hetzelfde model gemeten als elke kandidaat. Niet als norm — een menselijk rooster is geen bovengrens en geen ondergrens — maar als ijkpunt: het laat zien welke waarden een door mensen gemaakte structuur oplevert.

Het officiële rooster, gemeten met het kwaliteitsmodel

MAAT	WAARDE	WAT HET ZEGT
Kwaliteit totaal	80,7	Gewogen totaal van alle onderdelen
Kwaliteit zonder continuïteit	78,6	Zonder het onderdeel dat het rooster met zichzelf vergelijkt
Robuuste kwaliteit	64,9	Totaal, gewogen met de slechtste regel en uitschieters
Slechtste regel	15,6	De zwakste roosterregel in het hele pakket
Uren	70,3	Afwijking van 40:00 per rooster en per regel
Regelmaat	75,7	Stabiele opeenvolging van dagdelen
Rust	76,7	Rust boven het wettelijke minimum en herstel na nachten
Nachten	100,0	Losse nachten en reeksen van twee
Eerlijkheid	66,9	Verdeling van nachten, rangeerwerk en weekenden
Losse nachten	0	Nachtdiensten zonder buur
Zware overgangen	2	Nacht → vroeg, laat → vroeg en vroeg → nacht

De hoge continuïteitsscore van het officiële rooster is een meetkundig gegeven, geen prestatie: het rooster is zijn eigen referentie en scoort op dat onderdeel per definitie honderd. Daarom staat overal in dit rapport ook de variant zonder continuïteit.

Waar de machine het anders doet

Het officiële rooster heeft 4 nachtreeksen van drie of meer, een langste reeks van 6 en 0 losse nachten. Dat is precies het patroon dat de zoekmachine probeert na te streven: liever een blok van drie of vier nachten dan losse nachten verspreid over de week. De maat "patroonafstand" in hoofdstuk 11 meet hoe ver een kandidaat van dit menselijke patroon af ligt.

Architectuur van de zoekmachine

De keten van genereren tot selecteren, en wat waar wordt beslist

De v1.0.3-machine deed per kandidaat één solveropdracht met een eventuele reparatieronde. De v1.0.4-machine zet daar een meet- en selectielaag omheen: genereren, meten, verbeteren, selecteren.



De keten van de adaptieve zoekmachine. Alleen kandidaten die de harde validatie halen komen in de pool; kwaliteit kan een overtreding nooit compenseren.

De drie oordelen, strikt gescheiden



Wat de zoekmachine wel en niet mag variëren

Wel: zaadwaarden, zachte gewichten, vertrekpunten, welke roosters tijdens een reparatie vastliggen, en welke ruilen het bijschaven probeert. Niet: de dekking, de profielgrenzen, de geplande dagelijkse rust, het maximum aantal aaneengesloten diensten en alles wat de eindvalidatie toetst. Die staan in het model als harde eis en in de validatie als toets; geen enkele combinatie van gewichten kan ze afkopen.

Bijschaven met ruildiensten

De nieuwste laag is de goedkoopste: twee diensten van dezelfde weekdag van plaats wisselen en de kwaliteitsevaluator laten oordelen. Eén beoordeling kost ongeveer twee milliseconden, dus in de rekentijd van één solverstart passen tienduizenden varianten. De toets per ruil is precies de harde verzameling van het CP-SAT-model: dezelfde weekdag, dagdelen binnen het profiel, en de geplande dagelijkse rust bij alle vier de burens. Dekking, dienstgebruik en het aantal aaneengesloten diensten veranderen bij een ruil per definitie niet.

Het kwaliteitsmodel

Waaruit het oordeel bestaat en waarom het per regel meet

De kwaliteitsevaluator is bewust een apart onderdeel: hij kent de solver niet en de solver kent hem niet. Zo kan hij een kandidaat afkeuren die volgens de solverkosten uitstekend was.

Onderdelen van kwaliteitsmodel quality-model-v1

ONDERDEEL	GEWICHT	WAARUIT HET BESTAAT
hours	0,20	contract 0,75 · week 0,25
flow	0,20	stable 0,40 · penalty 0,30 · streak 0,30
rest	0,15	surplus 0,60 · recovery 0,25 · heavy 0,15
nights	0,20	clustering 1,00
fairness	0,15	nights 0,30 · shunting 0,30 · weekend 0,25 · longDuties 0,15
stability	0,10	sameDuty 0,40 · sameDaypart 0,60

De gewichten tellen op tot meer dan één; het totaal wordt genormaliseerd. Een onderdeel dat voor een pakket niet te meten is, valt weg en de rest wordt opnieuw gewogen — dat is beter dan een nul die als straf werkt.

Per roosterregel, niet alleen gemiddeld

Elk cijfer wordt ook per roosterregel berekend. Dat is het verschil tussen "het pakket zit gemiddeld op 40:00" en "iedere medewerker zit rond 40:00". De robuuste kwaliteit weegt daarom het totaal (0,85) met de slechtste regel (0,15), en trekt punten af wanneer een regel meer dan 35 punten onder de mediaan zakt. Zonder die weging kan een machine één regel opofferen om het gemiddelde op te poetsen.

Een regel zonder diensten krijgt geen cijfer

Tijdens de ontwikkeling bleek de slechtste regel van het officiële rooster een reserveweek te zijn: een regel zonder één gewerkte dienst. Die scoorde nul op alles wat met diensten te maken heeft en trok het oordeel omlaag terwijl er niets te beoordelen viel. Zulke regels krijgen nu geen cijfer. De slechtste regel van het officiële rooster ging daardoor van een structurele nul naar een echte zwakste regel, en de robuuste kwaliteit van het officiële rooster steeg mee. Dat is in beide fasen gelijk toegepast.

Een harde overtreding is geen kwaliteitsaftrek. Een kandidaat met één bevestigde overtreding wordt afgewezen, ook als hij op elk ander onderdeel de beste van de meting is.

De zoekstrategie

Budgetten, variatie, de kwaliteitspoort en de stopvoorwaarden

De zoektocht heeft een tijdsbudget, geen vaste routine. Binnen dat budget kiest de machine zelf hoeveel vertrekpunten, hoeveel reparaties en hoeveel bijschaafwerk er nog in passen.

De rekentijdmodi

MODUS	BUDGET	PER START	PER REPARATIE	BIJSCHAVEN	STARTS	ELITE
Snel (FAST)	2 min 00 s	20 s	10 s	8 s	3–4	8
Normaal (NORMAL)	5 min 00 s	40 s	15 s	15 s	3–4	12
Grondig (DEEP)	15 min 00 s	60 s	20 s	25 s	5–8	20
Zeer grondig (EXTENSIVE)	30 min 00 s	75 s	25 s	30 s	8–14	20

De benchmark in dit rapport is volledig in de modus Normaal gedraaid.

Wat de machine varieert

- **Zaadwaarden** — dezelfde opdracht met een andere zoekvolgorde levert een ander rooster op.
- **Zachte gewichten** — per start iets anders, zodat de starts niet in hetzelfde dal uitkomen.
- **Vertrekpunten** — latere starts krijgen de beste kandidaat mee als warme start, met de eis dat het resultaat voldoende verschilt.
- **Verplicht verschil** — een nieuwe kandidaat moet op ten minste 10% van de dienstdagen afwijken van wat er al ligt.

De kwaliteitspoort

Een kandidaat komt alleen in de pool als hij binnen de marges van het officiële rooster blijft: hoogstens 2 losse nachten meer, 2 zware overgangen meer, en niet meer dan 10 punten onder de robuuste kwaliteit van dat rooster. De poort is dus geen absolute drempel maar een vergelijking met wat mensen maken.

Wanneer het stopt

De zoektocht stopt als het budget op is, als er genoeg goede en voldoende verschillende kandidaten zijn, of als er 0,2 punten winst uitblijft over een reeks verbeterpogingen. Dat laatste heet hier een plateau: doorzoeken kost dan rekentijd zonder uitzicht.

Wijzigingen in code en configuratie

Welke onderdelen nieuw zijn, welke zijn aangepast en wat onaangeroerd bleef

Wat er aan de codebasis is veranderd, en waarom. De harde regels, de eindvalidatie en de publicatiepoort staan er niet tussen: die zijn niet aangeraakt.

Gewijzigde en nieuwe onderdelen

BESTAND	SOORT	WAT HET DOET
src/domain/quality-model.ts	nieuw	Het kwaliteitsmodel als configuratie: onderdelen, gewichten, drempels.
src/domain/quality-evaluator.ts	nieuw	De evaluator: meet uren, nachten, overgangen, rust, eerlijkheid en de slechtste regel.
src/domain/adaptive-search.ts	nieuw	De beslissingen: rangschikken, dubbelen, Pareto, poort, reparatie aanvaarden, plateau.
src/domain/roster-polish.ts	nieuw	Bijschaven met ruildiensten, met de harde toets per ruil.
src/server/generation/adaptive/engine.ts	nieuw	De zoektocht zelf: starts, bijschaven, reparatie, diversificatie, eindselectie.
src/server/generation/adaptive/pipeline.ts	nieuw	Voortgang, opslag van alleen de eindkandidaten, audit en eindstatus.
src/server/generation/adaptive/config.ts	nieuw	Budgetten en drempels op één geversioneerde plek.
src/server/generation/engine-flag.ts	nieuw	Schakelaar tussen de klassieke en de adaptieve zoekmachine.
python/cpsat_roster.py	gewijzigd	Vastgezette toewijzingen voor gerichte reparatie; instelbare lineaire ontspanning.
src/server/optimizer/cpsat-solver.ts	gewijzigd	Vastzettingen doorgeven, werkelijke zaadwaarde vastleggen.
prisma/schema.prisma	gewijzigd	Zoekmodus, zoekjournaal, tellers en herkomst per kandidaat.
src/domain/generation-progress.ts	gewijzigd	Voortgangsstappen van de adaptieve keten.
scripts/optimizer-benchmark.ts	nieuw	Eén benchmarkloper voor beide fasen, met manifest en hashcontrole.
scripts/benchmark/analyse.ts	nieuw	BEFORE tegenover AFTER, zonder selectie op gunstige uitkomsten.
scripts/measure-polish-budget.ts	nieuw	Meet wat extra bijschaftijd nog oplevert.

Het ontwikkellogboek

Elke aanpassing aan een gewicht of een drempel is vastgelegd met de oude waarde, de nieuwe waarde, de reden en het gemeten effect. Dat logboek staat in docs/optimizer-benchmark/development-log.json en is samengevat in hoofdstuk 9 en 16.

Gewichten en drempels

Welke getallen de zoektocht sturen en wat elke wijziging opleverde

De zachte gewichten bepalen wat de solver duur vindt. Ze zijn strafpunten ten opzichte van elkaar; de absolute grootte zegt niets.

Zachte gewichten per strategie

KOSTENPOST	BALANCED	REST_QUALITY	FAIR_BURDEN	MINIMAL_CHANGE	COVERAGE
hoursBalance	15	10	15	15	15
hoursWorst	40	25	40	40	40
restComfort	1	3	1	1	1
transitions	40	100	25	20	40
nightSingleton	900	1.100	900	400	900
nightPair	700	900	700	300	700
nightOutsideReference	400	400	400	400	400
nightFairness	12	12	60	12	12
shuntingFairness	6	6	35	6	6
weekendFairness	1	1	5	1	1
preserveReference	1	1	1	120	1
preserveHint	0	0	0	0	0

Wijzigingen met hun effect

NR	ONDERDEEL	WIJZIGING	GEMETEN EFFECT
D01	cpsat-optimizer.ts – solverstatistiek	De zaadwaarde in CpSatOutcomeExtras is de werkelijk gebruikte (options.seed) in plaats van die van de strategie.	Alleen registratie. Het zoeken zelf is ongewijzigd; commit e2b2091 vóór de eerste BEFORE-run.
D02	quality-evaluator.ts – regelscore	Een regel zonder één gewerkte dienst (alleen rust, reserve, WTV) krijgt geen regelscore.	Slechtste regel officieel: DDR-50MIX regel 2 (15,6: week 30:14, één zware overgang). Robuuste score officieel 58,7 → 64,9. Vastgesteld vóór enige AFTER-meting en vóór de BEFORE-evaluatie; beide fases worden met deze versie gemeten.
D03	objective-weights.ts – nightPair	nightPair 300 → 700 (BALANCED), REST_QUALITY 400 → 900, MINIMAL_CHANGE 140 → 300.	Eén meetrun: nachtclustering 78,9 → 89,5/100/100 en nachtverdeling 89,9 → 95,1; een tweede run met identieke gewichten gaf nachtverdeling 71,7. Les: nooit op één run afstemmen — aanleiding voor de meervoudige BEFORE/AFTER in v1.0.4.
D04	adaptive/engine.ts – gerichte CP-SAT-reparatie	Geen wijziging: de gerichte reparatie is gemeten zoals gebouwd (vrije roosters rond de zwakte, ouder als warme start, kostenpost 30 per afwijkende dienstdag, doelgewichten maal 4, 15 s).	5 reparaties, 0 aanvaard: 4x rangschikkingswinst 0 (waarvan 2 met solverstatus OPTIMAL), 1x verslechtering op nachtclustering (-5,3). Het kleine vraagstuk was met de ouder als warme start al optimaal; er viel binnen die vrijheidsgraden niets te winnen. Zoeken stopte op het plateau na 8 pogingen.
D05	roster-polish.ts (nieuw) – bijschaven met ruildiensten	Nieuwe zoeklaag naast CP-SAT: ruil twee diensten van dezelfde weekdag en beoordeel de uitkomst met de kwaliteitsevaluator (steilste beklimming, daarna herhaald schoppen en opnieuw klimmen). Toets per ruil precies de harde verzameling van het model: weekdag, dagdelen binnen het profiel, geplande dagelijkse rust bij alle vier de burens. Rekening per kandidaat: FAST 6 s, NORMAL 10 s, DEEP 15 s, EXTENSIVE 20 s.	Op drie BEFORE-kandidaten (BALANCED, 30 s per stuk, ~42.000 beoordeelde alternatieven): robuuste score 78,4 → 79,2 / 78,4 → 79,2 / 75,6 → 76,7; slechtste regel 59,4 → 63,6 / 59,4 → 63,6 / 50,0 → 53,1; hard geldig gebleven, patroonafstand tot het officiële rooster vrijwel gelijk (29,2 → 29,7 / 22,5 → 22,9 / 23,0 → 22,9). De winst zat vooral in rustcomfort en de slechtste regel; uren en nachtclustering bewogen nauwelijks. De eerste beklimming (circa 4 s) leverde vrijwel alle winst; de schoppen daarna zelden meer.
D06	adaptive/config.ts – polishSeconds per modus	Rekening voor bijschaven: Snel 8 s, Normaal 15 s, Grondig 25 s, Zeer grondig 30 s (was 6/10/15/20).	Gemiddelde winst in rangschikking: 5 s +0,71 10 s +1,10 20 s +1,30 40 s +1,49 80 s +1,59 160 s +1,66. Marge per seconde: 0,079 → 0,020 → 0,009 → 0,003 → 0,001; de knik ligt bij 20 s. De slechtste regel stijgt van 55,7 naar 60,2 en is bij 10 s al uitgewerkt. De patroonafstand tot het officiële rooster loopt bij lange budgetten langzaam op (25,6 → 26,3 bij 10 s → 27,7 bij 160 s): nog meer schaven wijkt verder af van de menselijke structuur voor steeds minder winst.
D07	werkwijze – mutatietesten naast lopende metingen	Geen codewijziging: een ablatierun die tijdens de mutatietesten startte, is weggegooid en opnieuw gedraaid.	Ablatierun 23 (no-transitions) startte binnen seconden van het mutatievenster. Niet aantoonbaar besmet — een al gestart Node-proces heeft zijn modules al geladen — maar niet uit te sluiten, en een meting die je moet verdedigen met 'waarschijnlijk niet' is geen meting.
D08	scripts/benchmark/analyse.ts – harde geldigheid	De toets op harde geldigheid leest een ja/nee nu ook als 1 of 0, niet alleen als `true`.	Het rapport concludeerde 'afgekeurd wegens een harde regressie' terwijl alle vier de harde toetsen slaagden en geen enkele kandidaat een bevestigde overtreding had. Na de correctie: beide fasen volledig hard geldig, 61 van de 61 AFTER-kandidaten met stand TECHNICALLY_VALID_UNVERIFIED_RULES.

Geen enkele waarde is op één run afgestemd. De les uit v1.0.3 staat in regel D03: dezelfde gewichten gaven in twee runs een verschil van meer dan twintig punten op nachtverdeling.

De AFTER-meting

Dezelfde benchmark, met de nieuwe zoekmachine


De AFTER-meting is exact dezelfde benchmark: hetzelfde pakket, dezelfde strategieën, hetzelfde aantal runs, dezelfde machine. Alleen de zoekmachine is anders.

De AFTER-meting per strategie

STRATEGIE	RUNS	KANDIDATEN	ROBUUST GEM.	ROBUUST MEDIAAN	LAAGSTE	HOOGSTE	REKENTIJD GEM.
BALANCED	10	30	79,2	79,4	77,5	80,5	4 min 39 s
REST_QUALITY	5	15	79,8	79,7	78,8	80,4	4 min 35 s
FAIR_BURDEN	5	15	79,3	79,3	77,3	81,6	4 min 35 s

Kandidaten per opdracht

Een opdracht levert drie kandidaten die voldoende van elkaar verschillen. In de AFTER-meting kwam dat 20 van de 21 keer uit; in de BEFORE-meting 20 van de 21 keer.



Robuuste kwaliteit per strategie: de balk loopt van de slechtste tot de beste kandidaat, met mediaan en gemiddelde. De gouden lijn is het officiële rooster.

Alle 60 AFTER-kandidaten zijn door de onafhankelijke eindvalidatie gegaan. De uitkomst daarvan staat in hoofdstuk 17.

BEFORE tegenover AFTER

De volledige vergelijking, inclusief wat achteruitging

Deze tabel is de kern van het rapport. Gemiddelde tegen gemiddelde, mediaan tegen mediaan, en — omdat een gemiddelde de pijn verbergt — ook de slechtste waarde tegen de slechtste waarde.

Alle gemeten maten, beide fasen, alle kandidaten

MAAT	OFFICIEEL	BEFORE GEM.	AFTER GEM.	Δ GEM.	Δ MEDIAAN	Δ SLECHTSTE
Kwaliteit totaal	80,7	81,1 ± 1,2	82,2 ± 0,8	+1,2	+0,8	+2,1
Kwaliteit zonder continuïteit	78,6	83,5 ± 1,2	84,7 ± 0,7	+1,3	+1,2	+2,6
Robuuste kwaliteit (pakket + slechtste regel)	64,9	77,0 ± 2,3	79,4 ± 0,8	+2,4	+1,8	+5,9
Uren	70,3	76,3 ± 0,3	76,9 ± 0,3	+0,6	+0,7	+0,4
Regelmaat	75,7	79,8 ± 1,2	80,4 ± 1,0	+0,7	+0,8	+0,7
Rust	76,7	77,0 ± 3,6	82,8 ± 3,1	+5,8	+6,4	+7,7
Nachten	100,0	96,9 ± 4,8	98,1 ± 3,0	+1,2	0,0	+5,3
Eerlijkheid	66,9	86,4 ± 3,5	85,1 ± 2,9	-1,4	0,0	+2,2
Continuïteit	100,0	59,5 ± 2,8	59,6 ± 3,4	+0,1	0,0	-1,2
Uren: gem. afwijking per basisrooster (lager = beter)	12,7	8,2 ± 0,1	8,2 ± 0,1	0,0	-0,1	+0,1
Uren: grootste afwijking per basisrooster (lager = beter)	48,0	20,8 ± 1,7	32,4 ± 6,4	+11,6	+13,0	+16,0
Uren: spreiding afwijking per basisrooster (lager = beter)	15,2	9,7 ± 0,3	11,9 ± 1,5	+2,2	+2,3	+4,3
Uren: gem. weekafwijking per regel (lager = beter)	291,1	276,2 ± 6,0	263,3 ± 7,5	-12,9	-12,4	-11,5
Uren: grootste weekafwijking per regel (lager = beter)	737,0	673,3 ± 46,4	664,0 ± 45,0	-9,3	-26,0	-21,0
Uren: regels buiten ±30 min (lager = beter)	56,0	54,7 ± 2,2	52,3 ± 2,3	-2,4	-3,0	-1,0
Losse nachten (lager = beter)	0,0	0,1 ± 0,4	0,2 ± 0,4	+0,1	0,0	0,0
Reeksen van twee nachten (lager = beter)	0,0	0,5 ± 0,8	0,2 ± 0,4	-0,3	0,0	-1,0
Nachtreeksen van drie of meer (lager = beter)	4,0	4,5 ± 0,6	4,6 ± 0,5	0,0	0,0	-1,0
Gemiddelde nachtrees (lager = beter)	4,8	3,8 ± 0,6	4,0 ± 0,5	+0,2	0,0	0,0
Langste nachtrees (lager = beter)	6,0	5,0 ± 0,5	5,2 ± 0,7	+0,2	0,0	0,0
Zware overgangen (lager = beter)	2,0	0,3 ± 0,4	0,0 ± 0,2	-0,2	0,0	0,0
Nacht → vroeg (lager = beter)	0,0	0,0 ± 0,0	0,0 ± 0,0	0,0	0,0	0,0
Laat → vroeg (lager = beter)	2,0	0,0 ± 0,2	0,0 ± 0,0	0,0	0,0	-1,0
Vroeg → nacht (lager = beter)	0,0	0,0 ± 0,0	0,0 ± 0,0	0,0	0,0	0,0
Overgangsstrafpunten (lager = beter)	13,0	3,6 ± 2,0	2,2 ± 1,4	-1,4	-1,0	-3,0
Dagdeelwisselingen per gewerkte dag (lager = beter)	0,0	0,0 ± 0,0	0,0 ± 0,0	0,0	0,0	0,0
Gemiddelde reeks in hetzelfde dagdeel	2,1	2,1 ± 0,0	2,2 ± 0,0	0,0	0,0	0,0
Rust boven minimum (score)	73,0	78,8 ± 1,0	82,6 ± 1,3	+3,7	+3,8	+3,3
Herstel na nachten (score)	82,5	60,1 ± 13,1	73,2 ± 11,9	+13,1	+15,2	+17,0
Kortste rust boven minimum	29,0	112,1 ± 25,5	92,5 ± 29,0	-19,6	-31,0	-1,0
Kortste herstel na nachtrees	56,0	34,3 ± 12,2	43,7 ± 9,8	+9,3	+14,1	+10,1
Eerlijke nachtverdeling	73,3	84,1 ± 8,8	79,6 ± 8,0	-4,5	0,0	0,0
Eerlijke rangeerverdeling	48,2	92,6 ± 2,8	93,3 ± 0,9	+0,7	0,0	+6,2
Eerlijke weekendbelasting	81,8	81,8 ± 0,0	81,8 ± 0,0	0,0	0,0	0,0
Nachten per regel: spreiding tussen nachtroosters (lager = beter)	0,2	0,1 ± 0,1	0,2 ± 0,1	0,0	0,0	0,0
Rangeer per regel: max – min tussen roosters (lager = beter)	0,9	0,1 ± 0,1	0,1 ± 0,0	0,0	0,0	-0,2

MAAT	OFFICIEEL	BEFORE GEM.	AFTER GEM.	Δ GEM.	Δ MEDIAAN	Δ SLECHTSTE
Slechtste regel	15,6	55,2 ± 7,7	63,1 ± 2,2	+7,9	+4,3	+14,0
Mediane regel	75,0	78,7 ± 2,1	80,9 ± 2,5	+2,2	+1,6	+0,3
Patroonafstand tot officieel (lager = beter)	0,0	21,3 ± 5,9	23,5 ± 4,7	+2,2	+1,9	+0,2
Zelfde dienstnummer als huidig (lager = beter)	100,0	42,6 ± 3,2	40,3 ± 2,9	-2,4	-3,1	-1,8
Zelfde dagdeel als huidig (lager = beter)	100,0	70,8 ± 3,3	72,5 ± 4,4	+1,8	+1,8	+2,7
Hard geldig (evaluator)	1,0	1,0 ± 0,0	1,0 ± 0,0	0,0	0,0	0,0
Bevestigde harde overtredingen (eindvalidatie) (lager = beter)	—	0,0 ± 0,0	0,0 ± 0,0	0,0	0,0	0,0
Profielovertredenen (lager = beter)	0,0	0,0 ± 0,0	0,0 ± 0,0	0,0	0,0	0,0
Niet geplaatste diensten (lager = beter)	0,0	0,0 ± 0,0	0,0 ± 0,0	0,0	0,0	0,0
Laat/Nacht: vroege diensten (lager = beter)	0,0	0,0 ± 0,0	0,0 ± 0,0	0,0	0,0	0,0

Van de 46 maten gingen er 26 vooruit en 12 achteruit op het gemiddelde. De kolommen mediaan en slechtste laten zien of dat over de hele verdeling geldt.

Per strategie

Robuuste kwaliteit per strategie

STRATEGIE	BEFORE GEM.	AFTER GEM.	Δ	BEFORE BESTE	AFTER BESTE	AFTER WINT (RANG)
BALANCED	77,4	79,7	+2,3	79,1	80,5	10/10
REST_QUALITY	78,8	80,0	+1,1	79,6	80,4	5/5
FAIR_BURDEN	77,9	79,7	+1,9	79,7	81,6	5/5

Per run de beste kandidaat, want dat is wat de Roostercommissie te zien krijgt.

Wat er achteruitging

- Eerlijkheid:** -1,4 op het gemiddelde (-1,6%), mediaan 0,0.
- Uren: grootste afwijking per basisrooster:** +11,6 op het gemiddelde (55,7%), mediaan +13,0.
- Uren: spreiding afwijking per basisrooster:** +2,2 op het gemiddelde (22,6%), mediaan +2,3.
- Losse nachten:** +0,1 op het gemiddelde (125,0%), mediaan 0,0.
- Nachtreeksen van drie of meer:** 0,0 op het gemiddelde (0,4%), mediaan 0,0.
- Gemiddelde nachtreeks:** +0,2 op het gemiddelde (3,9%), mediaan 0,0.
- Langste nachtreeks:** +0,2 op het gemiddelde (3,0%), mediaan 0,0.
- Kortste rust boven minimum:** -19,6 op het gemiddelde (-17,5%), mediaan -31,0.
- Eerlijke nachtverdeling:** -4,5 op het gemiddelde (-5,4%), mediaan 0,0.
- Nachten per regel: spreiding tussen nachtroosters:** 0,0 op het gemiddelde (31,4%), mediaan 0,0.
- Patroonafstand tot officieel:** +2,2 op het gemiddelde (10,5%), mediaan +1,9.
- Zelfde dagdeel als huidig:** +1,8 op het gemiddelde (2,5%), mediaan +1,8.

Deze punten staan ook in hoofdstuk 17 met een inschatting van het risico.

Per basisrooster en profiel

Of de winst overal zit, of ergens iemand ervoor betaalt

Een verbetering die alleen in het gemiddelde zit, kan één roosterprofiel hebben opgeofferd. Daarom per basisrooster — en daarmee per profiel — dezelfde vergelijking.

Op de slechtste roosterregel gingen 7 van de 7 basisroosters vooruit, en geen enkel rooster achteruit. Dat is de toets op het opofferen van één groep: een machine die het gemiddelde optilt door één profiel te laten inleveren, valt hier door de mand.

DDR-50MIX

MAAT	BEFORE GEM.	AFTER GEM.	Δ	AFTER SLECHTSTE
Afwijking van 40:00 (min)	0,2	0,3	+0,1	9,0
Nachten	0,2	0,0	-0,2	0,0
Zware overgangen	0,0	0,0	0,0	2,0
Stabiele opeenvolging	1,0	1,0	0,0	0,5
Slechtste regel	62,2	64,3	+2,0	15,6
Kortste herstel na nachten (u)	—	—	—	—

DDR-BLM

MAAT	BEFORE GEM.	AFTER GEM.	Δ	AFTER SLECHTSTE
Afwijking van 40:00 (min)	0,8	0,9	0,0	48,0
Nachten	4,4	4,2	-0,3	3,0
Zware overgangen	0,1	0,0	-0,1	1,0
Stabiele opeenvolging	1,0	1,0	0,0	0,9
Slechtste regel	63,5	67,5	+4,0	53,1
Kortste herstel na nachten (u)	44,4	52,4	+8,0	22,5

DDR-L

MAAT	BEFORE GEM.	AFTER GEM.	Δ	AFTER SLECHTSTE
Afwijking van 40:00 (min)	16,1	9,3	-6,8	21,0
Nachten	0,0	0,0	0,0	0,0
Zware overgangen	0,0	0,0	0,0	0,0
Stabiele opeenvolging	1,0	1,0	0,0	1,0
Slechtste regel	63,9	67,3	+3,4	59,4
Kortste herstel na nachten (u)	—	—	—	—

DDR-LN

MAAT	BEFORE GEM.	AFTER GEM.	Δ	AFTER SLECHTSTE
Afwijking van 40:00 (min)	0,0	0,1	+0,1	1,0
Nachten	5,4	6,1	+0,8	3,0
Zware overgangen	0,1	0,0	-0,1	0,0
Stabiele opeenvolging	1,0	1,0	0,0	0,9
Slechtste regel	60,5	63,7	+3,2	60,0
Kortste herstel na nachten (u)	55,4	61,6	+6,2	27,8

DDR-MIX

MAAT	BEFORE GEM.	AFTER GEM.	Δ	AFTER SLECHTSTE
Afwijking van 40:00 (min)	20,2	16,6	-3,7	41,0
Nachten	9,0	8,7	-0,3	8,0

MAAT	BEFORE GEM.	AFTER GEM.	Δ	AFTER SLECHTSTE
Zware overgangen	0,0	0,0	0,0	0,0
Stabiele opeenvolging	1,0	1,0	0,0	0,9
Slechtste regel	62,0	65,1	+3,1	63,3
Kortste herstel na nachten (u)	48,4	50,5	+2,1	46,0

DDR-V

MAAT	BEFORE GEM.	AFTER GEM.	Δ	AFTER SLECHTSTE
Afwijking van 40:00 (min)	20,7	30,3	+9,6	43,0
Nachten	0,0	0,0	0,0	0,0
Zware overgangen	0,0	0,0	0,0	0,0
Stabiele opeenvolging	1,0	1,0	0,0	1,0
Slechtste regel	65,7	68,7	+3,0	64,1
Kortste herstel na nachten (u)	—	—	—	—

DDR-VL

MAAT	BEFORE GEM.	AFTER GEM.	Δ	AFTER SLECHTSTE
Afwijking van 40:00 (min)	0,1	0,5	+0,4	5,0
Nachten	0,0	0,0	0,0	0,0
Zware overgangen	0,0	0,0	0,0	0,0
Stabiele opeenvolging	1,0	1,0	0,0	0,9
Slechtste regel	62,4	64,5	+2,1	56,8
Kortste herstel na nachten (u)	—	—	—	—

Laat en Nacht in detail

Nachtreeksen, herstel, verdeling en de absolute profieltoets

Nachtdiensten zijn het onderdeel waar een rooster het snelst onleefbaar wordt. Losse nachten zijn zwaarder dan een blok, en na een reeks hoort echt herstel. Dit hoofdstuk kijkt daar apart naar.

Nachtmaten, beide fasen

MAAT	OFFICIEEL	BEFORE GEM.	AFTER GEM.	Δ GEM.	Δ MEDIAAN	Δ SLECHTSTE
Losse nachten (lager = beter)	0,0	0,1 ± 0,4	0,2 ± 0,4	+0,1	0,0	0,0
Reeksen van twee nachten (lager = beter)	0,0	0,5 ± 0,8	0,2 ± 0,4	-0,3	0,0	-1,0
Nachtreeksen van drie of meer (lager = beter)	4,0	4,5 ± 0,6	4,6 ± 0,5	0,0	0,0	-1,0
Langste nachtreeks (lager = beter)	6,0	5,0 ± 0,5	5,2 ± 0,7	+0,2	0,0	0,0
Gemiddelde nachtreeks (lager = beter)	4,8	3,8 ± 0,6	4,0 ± 0,5	+0,2	0,0	0,0
Kortste herstel na nachtreeks	56,0	34,3 ± 12,2	43,7 ± 9,8	+9,3	+14,1	+10,1
Eerlijke nachtverdeling	73,3	84,1 ± 8,8	79,6 ± 8,0	-4,5	0,0	0,0
Nachten per regel: spreiding tussen nachtroosters (lager = beter)	0,2	0,1 ± 0,1	0,2 ± 0,1	0,0	0,0	0,0

De absolute toets: geen vroege dienst in een Laat/Nacht-rooster

Het Laat/Nacht-profiel staat geen vroege diensten toe. Dat is geen voorkeur maar een profielgrens, en hij zit als harde eis in het model én in de eindvalidatie. In de AFTER-meting is het aantal vroege diensten in een Laat/Nacht-rooster 0 over alle 60 kandidaten — zoals het hoort.

Deze toets is absoluut: één vroege dienst in een Laat/Nacht-rooster maakt de hele meting ongeldig, hoe goed de cijfers verder ook zijn.

Handmatige controle op de beste kandidaat

Gecontroleerd is de kandidaat met de hoogste robuuste kwaliteit uit de AFTER-meting: run 18 (FAIR_BURDEN), kandidaat 1, robuuste kwaliteit 81,6. De roosters zijn als raster uitgedraaid en met de hand nagelopen.

De gecontroleerde roosters

ROOSTER	NACHTEN	BLOKKEN	VROEGE DIENSTEN	SLECHTSTE REGEL	KORTSTE HERSTEL
DDR-LN	6	6	0	66,6	58,5 u
DDR-MIX	9	4,5	21	69,4	58,5 u
DDR-V	0	geen	41	68,8	—

De controlepunten

PUNT	BEVINDING	OORDEEL
Laat/Nacht: geen vroege diensten	0 vroege diensten in DDR-LN; alle diensten zijn laat of nacht.	akkoord
Nachten staan in blokken, niet los	DDR-LN: regel 2 heeft N761 op vrijdag, zaterdag en zondag; regel 3 vervolgt met N201, N201, N760 op maandag tot woensdag. Langs de rotatie is dat één reeks van zes. DDR-MIX heeft blokken van vier (regel 3, donderdag tot zondag) en vijf (regel 8, maandag tot vrijdag). Geen enkele losse nacht. De reeks van zes ontstaat over de regelgrens: wie alleen regel 2 leest ziet drie nachten. Het officiële rooster kent dezelfde vorm (langste reeks zes, gemiddeld 4,75), dus dit wijkt niet af van wat mensen maken.	akkoord
Herstel na een nachtreeks	Kortste herstel na nachten 58,5 uur in zowel DDR-LN als DDR-MIX; de regel eist 46 uur.	akkoord
Geen zware overgangen rond de regelgrens	Na elke nachtreeks volgen rustdagen: DDR-MIX regel 3 eindigt zondag op N760 en regel 4 begint maandag met een WTV-dag; regel 8 eindigt vrijdag en heeft zaterdag en zondag rust. Nergens nacht gevolgd door vroeg.	akkoord
Regelmaat binnen een regel	Dagdelen wisselen binnen een regel niet heen en weer. DDR-V regel 3 rijdt V7 op drie achtereenvolgende dagen, regel 4 rijdt V701 op drie dagen; DDR-MIX regel 7 heeft vier late diensten op rij.	akkoord
Ziet het eruit als een rooster dat je iemand kunt geven	Ja. Weken bestaan uit aaneengesloten blokken werk met rust ertussen, dezelfde dienst komt meerdere dagen terug en de weekenden zijn per regel heel of vrij.	akkoord
Regels zonder gewerkte dienst	DDR-V regel 7 bestaat uit reserve-, WTV- en rustdagen en heeft geen enkele gewerkte dienst. Dat komt uit de roosterstructuur, niet uit de zoekmachine; zo'n regel krijgt geen kwaliteitcijfer.	akkoord, structureel

Geen bevindingen die de meting in twijfel trekken. De beste AFTER-kandidaat leest als een normaal rooster: nachten in blokken met ruim herstel, geen vroege diensten in Laat/Nacht, rustige opeenvolging binnen elke regel.

Rekentijd

Wat het kost, waar het heen gaat en waar de opbrengst afvlakt

Meer rekentijd levert een beter rooster op, maar niet evenredig. Dit hoofdstuk zegt hoeveel het kost en waar de opbrengst afvlakt.

3 min 42 s

gemiddelde rekentijd per opdracht, v1.0.3

4 min 37 s

gemiddelde rekentijd per opdracht, v1.0.4

32.797

onderzochte varianten per geldige kandidaat

Waar de rekentijd heen gaat

BEZIGHEID	TOTAAL OVER ALLE AFTER-RUNS	PER RUN
Solver (CP-SAT)	51 min 36 s	2 min 35 s
Beoordelen en bijschaven	30 min 15 s	1 min 31 s
Eindvalidatie	5 min 10 s	16 s

Wat de rekentijdmodi opleveren

Dezelfde strategie in vier modi

MODUS	RUNS	REKENTIJD GEM.	ROBUUST GEM.	ROBUUST BESTE	Δ T.O.V. SNEL	SLECHTSTE REGEL
Snel	2	1 min 50 s	78,6	79,5	0,0	62,9
Normaal	2	4 min 45 s	79,4	80,1	+0,8	63,6
Grondig	2	13 min 42 s	79,4	79,7	+0,8	63,6
Zeer grondig	2	28 min 06 s	80,8	81,3	+2,2	65,2

Meer rekentijd betekent meer vertrekpunten, meer bijschaven en meer verbeterondes — niet andere regels. De winst vlakkt af: dat is de reden dat Normaal de standaard is.

Geheugen

Hoogste gemeten werkgeheugen per opdracht

PROCES	V1.0.3 GEM.	V1.0.3 PIEK	V1.0.4 GEM.	V1.0.4 PIEK
Solver (python.exe)	474 MB	519 MB	441 MB	475 MB
Zoekmachine (node.exe)	240 MB	273 MB	301 MB	332 MB

Elke twee seconden bemonsterd van buitenaf. De zoekmachine bewaart alleen de elitepool en het zoekjournaal; de duizenden bijgeschaafde varianten bestaan één voor één en worden niet bewaard.


Afnemende meeropbrengst van het bijschaven

Winst in rangschikking per bijschaafbudget

BUDGET	GEMIDDELDE WINST	MARGE PER SECONDE
5 s	+0,71	—
10 s	+1,11	0,0790
20 s	+1,31	0,0200
40 s	+1,49	0,0090
80 s	+1,59	0,0026
160 s	+1,66	0,0009

Gemeten op 4 kandidaten uit de BEFORE-meting met npm run measure:polish-budget.

De knik ligt bij twintig seconden: daarboven kost elke punt winst vier keer zoveel rekentijd. De modus Normaal staat daarom op vijftien seconden per kandidaat — onder de knik, en met genoeg budget over om voldoende verschillende kandidaten te vinden.



Elke opdracht: rekentijd tegen de beste kandidaat die hij opleverde. Grijs is v1.0.3, blauw v1.0.4.

Hoofdstuk 15

Zoekefficiëntie

Hoeveel werk er is verzet en hoeveel daarvan iets opleverde

Hoeveel werk de machine heeft verzet, en hoeveel daarvan iets opleverde. Een zoektocht die duizenden varianten bekijkt maar er niets aan verbetert, is dure schijnbeweging.

2.656.538 varianten beoordeeld	121 volledige solveropdrachten	81 kandidaten door de eindvalidatie	100% bijschaafrondes met winst
-----------------------------------	-----------------------------------	--	-----------------------------------

Wat elke stap opleverde, over alle AFTER-runs

STAP	POGINGEN	GESLAAGD	OPMERKING
Starts	60	60	Elke start levert een volledig rooster op
Bijschaven	121	121	1.453 ruilen, samen +97,6 punten rangschikking
Gerichte reparatie	61	21	36 keer werd het doel beter, 12 keer afgewezen wegens verslechtering elders
Afgewezen kandidaten	40	—	0 dubbel, 0 onder de poort

Ablatie: wat doet elk onderdeel?

Hetzelfde recept met telkens één ingrediënt eruit

OPSTELLING	RUNS	ROBUUST GEM.	Δ T.O.V. VOLLEDIG	LOSSE NACHTEN	ZWARE OVERGANGEN	SLECHTSTE REGEL
Volledige machine	10	79,2	—	0,03	0,03	63,1
zonder straf op losse nachten	3	76,9	−2,4	0,56	0,11	60,2
zonder straf op zware overgangen	3	78,1	−1,1	0,00	0,56	57,7
zonder gerichte reparatie	3	78,4	−0,8	0,11	0,22	62,4

Een negatief verschil betekent dat het weggelaten onderdeel iets bijdraagt: zonder dat onderdeel wordt de uitkomst slechter. Staat er ongeveer nul, dan doet het onderdeel in deze opstelling weinig.

Waarom de zoektocht stopte

REDEN	AANTAL RUNS
tijdsbudget voor reparatie op	20

Wat niet werkte

Aanpakken die zijn geprobeerd, gemeten en verworpen

Dit hoofdstuk staat er omdat het de volgende ontwikkelaar het meeste tijd bespaart. Wat hieronder staat is geprobeerd, gemeten en grotendeels niet gehouden.

De gerichte CP-SAT-reparatie leverde eerst niets op

Het idee: zet de roosters vast die niets met de zwakte te maken hebben, geef de solver de kandidaat als warme start en laat hem het kleine deel opnieuw indelen met verhoogde gewichten op het zwakke onderdeel. In de eerste rookproef werden alle vijf de reparaties afgewezen: vier leverden nul winst op — twee daarvan met solverstatus OPTIMAL — en één verslechterde de nachtclustering. Het kleine vraagstuk was met de ouder als warme start dus al optimaal. De reparatie is blijven bestaan, maar hij is niet het werkpaard; over de hele AFTER-meting werd 34% van de reparaties aanvaard.

En de reparatie bleef ook daarna het zwakke onderdeel

De ablatiemeting zet de gerichte reparatie helemaal uit. Zonder die stap komt de robuuste kwaliteit uit op 78,4 tegen 79,2 met de volledige machine — een verschil van $-0,8$ punten — terwijl een opdracht 1 min 27 s korter duurt. Met 3 runs is dat te weinig om te zeggen dat de reparatie niets bijdraagt, maar te weinig verschil om te doen alsof zij het werk doet. Het bijschaven is de motor; de reparatie is bijwerk dat af en toe iets oplevert.

Uren repareren is zinloos werk

De diagnose koos in het begin vaak "uren" als doelwit, omdat de urenscore het verst van de honderd af ligt. Maar die afstand is structureel: de diensten in het pakket hebben de lengtes die ze hebben, en de roostercyclus moet uitkomen op 40:00 gemiddeld. Wat er te winnen viel, had de solver in de eerste seconden al gewonnen. Een lage score is dus geen bewijs dat er iets te halen valt.

Bijschaven zonder grens loopt weg van het menselijke patroon

Bij lange bijschaafbudgetten blijft de rangschikking stijgen, maar de patroonafstand tot het officiële rooster loopt langzaam op. Met andere woorden: de machine wint punten door verder van de menselijke structuur af te gaan liggen. Dat is precies het risico van optimaliseren op een maat. Daarom is het budget begrensd op de knik van de curve en niet op het punt waar de score het hoogst is.

Drie mechanismen die niets deden

Alle 20 opdrachten stopten om dezelfde reden: tijdsbudget voor reparatie op. De plateaudetectie — stoppen zodra een reeks verbeterpogingen niets meer oplevert — is dus geen enkele keer in werking getreden. In de langere modi gebeurde dat wel: bij DEEP en EXTENSIVE stopte het zoeken op een plateau, ruim vóór het budget op was. De dubbelherkenning wees geen enkele kandidaat af: de starts leverden vanzelf voldoende verschillende roosters op. De kwaliteitspoort, geijkt op het officiële rooster, hield ook niets tegen: geen enkele kandidaat zakte eronder. Dat betekent niet dat die mechanismen overbodig zijn — ze zijn er voor het pakket waarin het wél misgaat — maar in deze meting hebben ze weinig bewezen, en dat is iets anders dan dat ze werken.

Eén run is geen meting

In v1.0.3 is een gewicht aangepast op basis van één gunstige run; een tweede run met dezelfde gewichten gaf een twintig punten lagere nachtverdeling. Die ervaring is de reden dat deze hele meting uit tientallen runs bestaat en dat elk cijfer in dit rapport met een spreiding staat.

Wat hier staat is geen mislukking van het experiment maar het resultaat ervan: de winst komt niet van de slimste bedachte techniek, maar van de goedkoopste die daadwerkelijk op de gemeten kwaliteit stuurde.

Regressies en risico's

Wat slechter werd, wat hard is getoetst en wat er mis kan gaan

Wat er slechter van werd, en wat er mis kan gaan. Een rapport dat alleen de winst noemt, is een verkooptekst.

Harde toetsen

TOETS	BEFORE	AFTER	EIS	UITKOMST
Vroege diensten in een Laat/Nacht-rooster	0	0	0	gehaald
Diensten buiten het roosterprofiel	0	0	0	gehaald
Dienstdagen zonder dienstnummer	0	0	0	gehaald
Bevestigde harde overtredingen	0	0	0	gehaald

Validatiestanden

STAND	BEFORE	AFTER
TECHNICALLY_VALID_UNVERIFIED_RULES	61	61

De stand TECHNICALLY_VALID_UNVERIFIED_RULES betekent: geen bevestigde harde overtreding, wel regels waarvan de bron nog niet formeel is bevestigd. Die stand is in v1.0.3 en v1.0.4 gelijk en verandert niets aan de publicatiepoort.

Maten die achteruitgingen

MAAT	Δ GEMIDDELDE	Δ MEDIAAN	Δ SLECHTSTE	RISICO
Eerlijkheid	-1,4	0,0	+2,2	Zie hoofdstuk 11 en het ontwikkellogboek
Uren: grootste afwijking per basisrooster	+11,6	+13,0	+16,0	Zie hoofdstuk 11 en het ontwikkellogboek
Uren: spreiding afwijking per basisrooster	+2,2	+2,3	+4,3	Zie hoofdstuk 11 en het ontwikkellogboek
Losse nachten	+0,1	0,0	0,0	Zie hoofdstuk 11 en het ontwikkellogboek
Nachtreksen van drie of meer	0,0	0,0	-1,0	Zie hoofdstuk 11 en het ontwikkellogboek
Gemiddelde nachtreks	+0,2	0,0	0,0	Zie hoofdstuk 11 en het ontwikkellogboek
Langste nachtreks	+0,2	0,0	0,0	Zie hoofdstuk 11 en het ontwikkellogboek
Kortste rust boven minimum	-19,6	-31,0	-1,0	Zie hoofdstuk 11 en het ontwikkellogboek
Eerlijke nachtverdeling	-4,5	0,0	0,0	Zie hoofdstuk 11 en het ontwikkellogboek
Nachten per regel: spreiding tussen nachtroosters	0,0	0,0	0,0	Zie hoofdstuk 11 en het ontwikkellogboek
Patroonafstand tot officieel	+2,2	+1,9	+0,2	Zie hoofdstuk 11 en het ontwikkellogboek
Zelfde dagdeel als huidig	+1,8	+1,8	+2,7	Zie hoofdstuk 11 en het ontwikkellogboek

Risico's die niet in een getal passen

- **Optimaliseren op de eigen maat.** Het bijschaven stuurt rechtstreeks op de kwaliteitsevaluator. Wordt die maat ooit aangepast, dan verandert het gedrag van de machine mee. Daarom is het model geversioneerd en staat de versie bij elke kandidaat.
- **Rekentijd.** Een opdracht duurt langer dan in v1.0.3. Wie snel iets wil zien, kiest de modus Snel; die levert een minder verfijnd rooster op en dat staat ook in de handleiding.
- **Meer verandering ten opzichte van het huidige rooster.** Breder zoeken betekent roosters die verder van het bestaande af liggen. Voor wie dat niet wil, is er de strategie met minimale wijziging.

Testresultaten

Welke tests zijn gedraaid en wat ze zeiden

De volledige testbatterij, gedraaid op de code waarmee de AFTER-meting is gemaakt.

Testuitslagen van 18-9-2026, 11:15:56

SUITE	OPDRACHT	UITKOMST	SAMENVATTING	DUUR
Typecontrole	<code>npm run typecheck</code>	geslaagd		2 s
Codestijl	<code>npm run lint</code>	geslaagd	688:24 warning 'g' is defined but never used. Allowed unused args must match /^_u @typescript-eslint/no-unused-vars · 1661:22 warning 'g' is defined but never used. Allowed unused args must match ...	7 s
Enheidstests	<code>npm test</code>	geslaagd	Test Files 46 passed (46) · Tests 790 passed (790) · Start at 10:58:39 · Duration 12.62s (transform 9.79s, setup 0ms, import 15.67s, tests 29.27s, environment 5ms)	13 s
Mutatietests	<code>npm run verify:mutanten</code>	geslaagd	✓ bijschaven: de beste stand wordt niet bewaard, de laatste wel · 1 bewering(en) rood, o.a. tests/domain/bijschaven.test.ts > bijschaven met ruiddiensten > houdt de beste stand vast, ook als een schop in een slechtere...	1 min 24 s
Regels	<code>npm run verify:rules</code>	geslaagd	Gevalideerde regels 2 van 71 · Het regelbestand is structureel in orde. · Production-safe: NO — simulation/development only	0 s
Regeldekking	<code>npm run verify:rule-coverage</code>	geslaagd	regel die hij voedt, of op de blokkade die hij oplevert. · Formele validatie door NS: 0 van de 71. Een test bewijst dat de code doet wat er staat; niet dat · wat er staat juridisch klopt. Zolang de Arbeidstijdenwet en...	1 s
Roosteruren	<code>npm run verify:roster-hours</code>	geslaagd	Spreiding tussen de roosters: 39:12 tot 39:59 (0:47 verschil). · ✓ geen enkel rooster is structureel lichter of zwaarder dan de andere · ...	1 s
Kwaliteitsmodel	<code>npm run verify:quality</code>	geslaagd	Optimale totaalbalans — kandidaat 3: totaal 82 robuust 78.6 patroonafstand 29.9 · 223/223 diensten geplaatst grootste afwijking van 40:00: 19 min (DDR-L) slechtste regel: DDR-50MIX regel 6 (59.4) — week 48:29 · ✓ ...	1 s
Roosterkwaliteit	<code>npm run verify:kwaliteit</code>	geslaagd	Optimale totaalbalans — kandidaat 3: totaal 82 robuust 78.6 patroonafstand 29.9 · 223/223 diensten geplaatst grootste afwijking van 40:00: 19 min (DDR-L) slechtste regel: DDR-50MIX regel 6 (59.4) — week 48:29 · ✓ ...	1 s
Profielen	<code>npm run verify:profielen</code>	geslaagd	✓ de generatie weigert deze kandidaat — 18 dienst(en) buiten het roosterprofiel. Een dienst die het profiel niet toestaat, zoals een vroege dienst in Laat/Nacht, wordt nooit bewaard. · ✓ de weigering noemt het rooster...	5 s
Scenario's	<code>npm run verify:scenarios</code>	geslaagd	✓ elke dienst uit het pakket levert precies één dienstinstantie op · ✓ geen twee diensten delen dezelfde sleutel standplaats+weekdag+nummer · ... 23 con...	15 s
Structuurgeneratie	<code>npm run verify:structuurgeneratie</code>	geslaagd	✓ 14 is deelbaar door 2, zoals het lokale kader voor Dordrecht vraagt · ✓ een niet-deelbaar aantal (13) wordt door de regel zelf ook herkend als niet-deelbaar · ...	1 s
Toegang per rol	<code>npm run verify:toegang</code>	geslaagd	Beeldmerk zonder sessie · ✓ /brand/ns-logo.svg → 200 · Geweigerde toegang vastgelegd in het beveiligingslog: 72 · Alle rollen gedragen zich zoals verwacht.	17 s
Schermen	<code>npm run verify:schermen</code>	geslaagd	✓ alle 119 letterlijke interne verwijzingen wijzen naar een route · ✓ /roostercommissie/pakketten/sjabloon (8508 bytes) · ... 40 schermen in orde, 0 met bevin...	11 s
Doorloop (e2e)	<code>npm run verify:e2e</code>	geslaagd	Dekking van de gevraagde doorloop · afgedekt en geslaagd 71/71 · De hele doorloop is aangetoond op echte gegevens.	12 min 22 s
Crashherstel	<code>npm run verify:crash-recovery</code>	geslaagd	Wat hiermee niet is aangetoond: dat een defecte schijf geen gegevens kan · kwijtraken. Dat kan geen enkele software garanderen. Wat is aangetoond, is · dat wat bevestigd is een harde stop overleeft, en dat de instelli...	38 s
Productiebouw	<code>npm run build</code>	geslaagd	./src/server/optimizer/cpsat-optimizer.ts · ./src/server/generation/generation-job.ts · ./src/server/services/generation-service.ts · ./src/app/(app)/roostercommissie/genereren/voortgang/route.ts	1 min 17 s
Draagbare bundel	<code>npm run verify:portable</code>	geslaagd	Opruimen · X: losgekoppeld en de proefmap verwijderd. · ... 51 controles geslaagd, 0 mislukt, 0 geblokkeerd.	31 s

Wat de tests van de zoekmachine vastleggen

Synthetische roosters. De kwaliteitsevaluator wordt getoetst op paren roosters die op één ding verschillen: dezelfde diensten in reeksen tegenover heen-en-weer, alle roosters binnen vijf minuten van 40:00 tegenover een spreiding van een uur, twee reeksen van drie nachten tegenover zes losse nachten, rust net boven het minimum tegenover ruim, en dezelfde rangeerbelasting gelijk verdeeld tegenover geconcentreerd. Zet het model het slechte voorbeeld niet lager, dan meet het niet wat het zegt te meten — en dan is elke benchmarkuitkomst erna betekenisloos.

Mutatietests. In de broncode wordt opzettelijk één fout gezet, waarna de tests moeten omvallen. Uitkomst: ✓ bijschaven: de beste stand wordt niet bewaard, de laatste wel · 1 bewering(en) rood, o.a. tests/domain/bijschaven.test.ts > bijschaven met ruiddiensten > houdt de beste stand vast, ook als een schop in een slechtere... Nieuw in v1.0.4 zijn de mutaties op de zoekmachine zelf: een losse nacht die even zwaar telt als een nacht in een reeks, een zware overgang die niet meer als zwaar wordt geteld, urenafwijking zonder absolute waarde, een rangschikking die de slechtste regel negeert, en drie op het bijschaven — ruilen buiten het profiel, ruilen zonder rusttoets, en het niet bewaren van de beste stand.

Drie van die zeven mutaties bleven bij de eerste poging onopgemerkt. Niet omdat de code fout was, maar omdat de tests het verkeerde vastlegden: de profieltest werd al door de rusttoets afgevangen en kwam nooit aan de profielgrens toe. Die tests zijn aangepast, niet de mutaties.

Bekende beperkingen

Waar deze meting niets over zegt

Wat deze meting niet zegt.

- **Eén standplaats, één dienstenpakket.** Alles is gemeten op DDR met pakket DDR-BDU-05-10-2026-V1. Een ander pakket kan andere knelpunten hebben.
- **Eén machine.** De rekentijden gelden voor de machine in hoofdstuk 2. Op minder kernen duurt alles langer; de budgetten zijn tijdsbudgetten, dus de machine doet dan minder werk in dezelfde tijd.
- **Geen uitspraak over mens tegenover machine.** Het officiële rooster is een ijkpunt op dezelfde maten, geen deelnemer aan een wedstrijd.
- **De maat is niet de werkelijkheid.** Het kwaliteitsmodel is een model. Het meet wat we konden onderbouwen uit de regels en uit het officiële rooster; wat een machinist ervan vindt, staat er niet in.
- **Het aantal zoekdraden is niet apart gemeten.** Beide fasen draaiden met hetzelfde aantal solverdraden, dus de vergelijking klopt; of een ander aantal draden betere roosters oplevert, is met deze meting niet te zeggen.
- **Het bijschaven kent alleen ruilen van twee diensten.** Verplaatsingen met drie of meer diensten tegelijk zijn niet onderzocht; er kunnen verbeteringen bestaan die alleen zo bereikbaar zijn.
- **Regelbron nog niet bevestigd.** Enkele profielregels komen uit een overgenomen bron en hebben de stand POTENTIAL. Dat blijft ongewijzigd; de generatiepoort weigert die kandidaten hoe dan ook.

Fouten opsporen

Van kandidaat terug naar de beslissing die hem maakte

Hoe je van een kandidaat terugredeneert naar de beslissing die hem opleverde.

Wat er per kandidaat wordt bewaard

- De herkomst: welke poging, welke zaadwaarde, welke gewichten, welk vertrekpunt, welke reparaties.
- Waarom hij overleefde: welke drempels hij haalde en welke kandidaten hij versloeg.
- Het kwaliteitsrapport: alle onderdelen, per roosterregel, met de slechtste regel apart.
- De versies: kwaliteitsmodel en zoekmachine, zodat later duidelijk is waarmee is gemeten.

Van vraag naar antwoord

VRAAG	WAAR HET ANTWOORD STAAT
Waarom is deze kandidaat gekozen?	Het veld <code>provenance</code> bij de kandidaat: drempels, verslagen concurrenten, uitleg per zwak punt.
Wat heeft de machine geprobeerd?	Het zoekjournaal bij de opdracht: elke poging met zaadwaarde, gewichten, uitkomst en reden van afwijzing.
Waarom is deze dienst hier geplaatst?	De uitleg bij de kandidaat noemt de concurrerende diensten op die weekdag en waarom de ruil niet is gemaakt.
Kan ik deze kandidaat opnieuw maken?	<code>npm run reproduce:candidate -- <id></code> draait dezelfde opdracht met dezelfde zaadwaarde en vergelijkt de uitkomst.
Klopt het cijfer nog?	<code>npm run verify:quality</code> rekent het officiële rooster en de synthetische voorbeelden opnieuw door.

Er wordt niets uitgelegd wat niet in de gegevens staat. Een uitleg als "dit rooster is rustiger" zonder bijbehorende meting is misleidend; de uitleg noemt daarom altijd de maat en het getal waar hij op slaat.

Reproduceerbaarheid

Hoe elke meting opnieuw te draaien is

Elke meting in dit rapport is opnieuw te draaien. Dit hoofdstuk zegt hoe.

De meting stap voor stap

STAP	OPDRACHT	LEVERT OP
Conditie vastleggen	<code>npm run verify:optimizer-benchmark -- manifest --phase before</code>	manifest.json
BEFORE meten	<code>npm run verify:optimizer-benchmark -- run --phase before --engine legacy --strategy BALANCED --runs 10</code>	before/run-*.json
AFTER meten	<code>npm run verify:optimizer-benchmark -- run --phase after --engine adaptive --mode NORMAL --strategy BALANCED --runs 10</code>	after/run-*.json
Doorrekenen	<code>npm run verify:optimizer-benchmark -- evaluate</code>	benchmark-summary.json, tables/, CSV
Vergelijken	<code>npm run analyse:optimizer</code>	analysis.json
Bijschaafbudget meten	<code>npm run measure:polish-budget</code>	polish-budget.json
Rapport bouwen	<code>npm run report:optimizer</code>	dit document

Waarom een AFTER-run weigert te starten

De benchmark vergelijkt vóór elke AFTER-run de vingerafdruk van de gegevens, de profielen, het regelbestand en de machine met die van de BEFORE-meting. Wijkt er iets af, dan start hij niet. Een vergelijking die eigenlijk over gewijzigde invoergegevens gaat, is geen engine-experiment.

Terug naar v1.0.3

De klassieke zoekmachine blijft beschikbaar met `NS_OPTIMIZER_ENGINE=legacy`. De keuze verandert niets aan de regels, de validatie of de publicatiepoort — alleen aan hoe de kandidaten tot stand komen.

Wat niet volledig reproduceerbaar is: CP-SAT met meerdere zoekdraden geeft ook met dezelfde zaadwaarde niet altijd exact hetzelfde rooster, omdat draden elkaar in wisselende volgorde vinden. Daarom vergelijkt `reproduce:candidate` op afstand en kwaliteit, en niet op een identieke uitkomst.

Conclusie en besluit

Wat is aangetoond, wat niet, en wat er nu gebeurt

Wat de meting laat zien, wat het besluit is en wat dat betekent voor wie het platform gebruikt.

Wat er is aangetoond

- Robuuste kwaliteit: $77,0 \rightarrow 79,4 (+2,4)$, gemeten over 60 en 60 kandidaten.
- Slechtste roosterregel: $55,2 \rightarrow 63,1 (+7,9)$. Dat is de regel waar één medewerker het hele jaar mee leeft.
- 7 van de 8 kernmaten vooruit, 1 achteruit.
- Geen enkele harde toets is verslechterd: 4 van de 4 toetsen gehaald.

Wat er niet is aangetoond

- Dat de machine betere roosters maakt dan roostermakers. Dat is met deze meting niet te zeggen en wordt hier niet beweed.
- Dat de winst op elk dienstenpakket terugkomt. Er is één pakket gemeten.
- Dat de gemeten kwaliteit overeenkomt met wat medewerkers ervaren. Het model meet wat te onderbouwen was, niet wat mensen ervan vinden.

Besluit: de adaptieve zoekmachine wordt de standaard, met de kanttekeningen uit hoofdstuk 17. De v1.0.3-machine blijft bereikbaar via een schakelaar.

Wat de gebruiker merkt

Een opdracht duurt langer en het scherm laat zien hoeveel varianten er zijn onderzocht. De uitkomst heet "beste gevonden kandidaat", niet "perfect rooster": de machine zoekt in een ruimte die te groot is om uitputtend te doorzoeken, en weet dus nooit of er iets beters bestond. Wat er ligt, is wel volledig doorgerekend, onafhankelijk gevalideerd en herleidbaar tot de beslissing die het opleverde.